

PONTIFICIA UNIVERSIDAD JAVERIANA
FACULTAD DE INGENIERÍA
PROYECTO DE GRADO
DEPARTAMENTO DE INGENIERÍA ELECTRÓNICA

**Diseño e implementación de un sistema
para la estimación de la estabilidad
postural: relación EEG-Presión plantar**

Daniel Andrés Pineda Suárez

Digirido por:
Martha Zequera Díaz, Ph.D.

Francisco Calderón Bocanegra, Ph.D.

Bogotá, Colombia
28 de noviembre de 2022

Agradecimientos

Agradezco a mi directora Martha Zequera por sus pertinentes observaciones y recomendaciones. A mi codirector Francisco Calderón por su valiosa orientación y retroalimentación.

A mis hermanitos menores, Samuel y Sofía. A mi tío Yohan, la figura paterna que con sus consejos contribuyó que me centrara en lo realmente importante. A mis amigos de toda la vida Nicolás Carreño y Leonardo Suárez. A Diego Díaz, David Castellanos, Víctor Viecco, Cristian Durán, Julián Oviedo y todos mis amigos de ingeniería electrónica por hacer este camino mucho más ameno y acompañarme en los momentos más complicados.

Y finalmente, dedicado a mi madre Saydeé, mi abuelita Adela y mi tía Carolina, los tres pilares de mi vida, quienes siempre me han apoyado en todo lo que emprendo de manera incondicional; haciendo hasta lo imposible por que cumpla mis sueños y cuyo amor, fe, paciencia y compañía se convirtieron en el baluarte que impulsó continuar.

Índice

Índice de cuadros	6
Índice de figuras	6
1 Introducción	1
1.1 Planteamiento del problema, posibles usuarios y justificación	1
1.2 Antecedentes y estado del arte	1
1.2.1 The Research in a Plantar Pressure Measuring System Connected with EEG	1
1.2.2 Real-Time Feedback of Body Center of Gravity for Postural Training of Elderly Patients with Peripheral Neuropathy	2
1.2.3 Postural stability analysis — A review of techniques and methods for human stability assessment	2
1.2.4 PAPPI: Personalized analysis of plantar pressure images using statistical modelling and parametric mapping	3
1.2.5 Estimation of the Center of Mass of Humanoid Robot	3
1.2.6 Úlceras diabéticas y neuropáticas	4
1.2.7 EEG features during maintaining a human body balance	4
1.2.8 Fabric-Based Wearable Dry Electrodes for Body Surface Biopotential Recording	5
1.2.9 Specific movement detection in EEG signal using time-frequency Analysis	6
1.2.10 EEG Data Analysis:	6
2 Objetivos general y específicos	8
2.1 Objetivo general	8
2.2 Objetivos específicos	8
3 Requerimientos del cliente	8
4 Estándares	9
5 Marco teórico	9
5.1 Equilibrio y centro de masa	9
5.2 Parámetros presentes en la conservación del equilibrio	10
5.2.1 Centro de presión (COP):	10
5.2.2 Base de sustentación	11
5.3 Estabilometría	11
5.4 Electroencefalografía	11
5.5 Áreas de Brodmann	12
5.6 Sistemas que intervienen en el equilibrio biológico	13
5.7 Filtro digital	15
5.8 Transformada de Wavelet Discreta	16
5.9 Transformada de Welch	16
6 Metodología	18
6.1 Diagrama de bloques	18
6.2 Protocolo de toma de datos	19
6.3 Registro de electroencefalografía:	19
6.4 Registro de estabilometría y presión plantar	23
6.5 Procesamiento de datos	24

6.5.1	Digitalización gráficas de estabilometría	25
6.5.2	Conversión de archivos	25
6.5.3	Filtrado de canales EEG	26
6.6	Extracción de características	27
6.6.1	Análisis en PSD	28
6.6.2	Normalización de canales	28
6.6.3	Valores máximo y mínimo absolutos	28
6.6.4	Desviación estándar	29
6.6.5	Matriz de salida	29
6.7	Métodos de aprendizaje de máquina	30
6.7.1	Gaussian Progress Regression (Optimizable GPR)	30
6.7.2	Gaussian Progress Regression (Squared Exponential GPR)	31
6.7.3	Kernel Naive Bayes	32
7	Resultados	33
7.1	Justificación de la visualización de los resultados	33
7.2	Resultados de distribucion de PSD: Ojos Abiertos vs Ojos Cerrados	33
8	Análisis de resultados	35
8.0.1	Primer voluntario	35
8.0.2	Segundo voluntario	36
8.0.3	Tercer voluntario	36
8.0.4	Cuarto voluntario	37
8.0.5	Quinto voluntario	38
9	Conclusiones	39
10	Trabajos futuros	40
11	Anexos	40
	Referencias	41

Índice de cuadros

1	Bandas de frecuencia de electroencefalografía	12
2	Vector de características extraido por cada toma de datos	29
3	Resultados de entrenamiento - Optimizable GPR	30
4	Resultados de entrenamiento - Squared Exponential GPR	31
5	Gráfico de predicciones - Kernel Naive Bayes	32
6	MCC - Estabilidad/Inestabilidad	33

Índice de figuras

1	Diagrama de bloques, <i>medición de presión plantar</i> . Tomado de [1]	2
2	Posición de los pies en toma de datos con pacientes. Tomada de [2]	2
3	Desplazamiento mediolateral (arriba) y desplazamiento anteroposterior (abajo). Tomada de [2].	2
4	Diagrama de estimación del centro de masa de robot humanoide. Tomado de [3]	3
5	Modelado en péndulo invertido, robot humanoide. Tomada de [3]	4
6	Despliegue de estimación del centro de masa, del humanoide teniendo en cuenta ángulos de distribución de peso. Tomada de [3].	4
7	Caracterización espectral de canales EEG, en tres sesiones de toma de muestras. Tomado de [4]	5
8	Comparativa entre señales tomadas con electrodos secos y electrodos húmedos, sentado vs en marcha respectivamente. Tomado de [5]	6
9	Misma señal EEG sometida a cuatro diferentes ventanas: Hamming, Hanning, Bartlett, Kaiser. Tomado de [6]	6
10	Gráfica datos EEG, obtenida mediante Google Colab	7
11	Potencial de acción. Tomado de [7]	12
12	Áreas de Brodmann. Tomado de [8]	13
13	Oído interno. Tomado de [9]	14
14	Cilios. Tomado de [10]	14
15	Partes del ojo. Tomado de [11]	15
16	Tacto. Tomado de [12]	15
17	Función de transferencia de un filtro digital	15
18	Estructura de la transformada discreta de Wavelet. Tomado de [13]	16
19	Periodograma de Welch de señal coseno en Matlab	18
20	Diagrama de bloques de la solución propuesta	18
21	Toma de datos sincrónica de estabilometría y EEG	19
22	Emotiv Epoch+	20
23	Disposición de los electrodos del Emotiv Epoch+	20
24	Batería y conectividad del Emotiv Epoch+	21
25	Calidad de contacto de los electrodos	21
26	Calidad de las señales de EEG	22
27	Dinámica de parpadeo en canales del Epoch+ - Voltaje vs Tiempo	22
28	Ficha de registro de individuos, Ecofoot	23
29	Registro de presión plantar, Ecofoot	24
30	Gráficas de estabilometría - centros de presión, oscilación lateral y anteroposterior, Ecofoot	24
31	Diagrama de flujo algoritmo de conversión de archivos de estabilometría	26
32	Diagrama de flujo algoritmo de conversión de archivos de electroencefalografía	26

33	Respuesta característica en potencia espectral, de un canal de electroencefalografía	27
34	Respuesta en frecuencia y fase del filtro empleado. Obtenida de Matlab	27
35	Condicional de máximo absoluto estabilométrico.	29
36	Gráfico de predicciones - Optimizable GPR	31
37	Gráfico de predicciones - Squared Exponential GPR	31
38	Curva ROC - Kernel Naive Bayes	32
39	Matriz de confusión - Kernel Naive Bayes	32
40	Distribución de las bandas α y β en canales de EEG: Toma de datos completa (5 sujetos) - Ojos abiertos.	34
41	Distribución de las bandas α y β en canales de EEG: Toma de datos completa (5 sujetos) - Ojos cerrados.	34
42	Toma de datos: Voluntario 1 - Ojos cerrados vs ojos abiertos.	35
43	Toma de datos: Voluntario 2 - Ojos cerrados vs ojos abiertos.	36
44	Toma de datos: Voluntario 3 - Ojos cerrados vs ojos abiertos.	36
45	Toma de datos: Voluntario 4 - Ojos cerrados vs ojos abiertos.	37
46	Toma de datos: Voluntario 5 - Ojos cerrados vs ojos abiertos.	38

1. Introducción

1.1. Planteamiento del problema, posibles usuarios y justificación

Las enfermedades crónicas en adultos mayores tienen una incidencia directa en cifras, tanto de discapacidad como de mortalidad en el mundo. Es debido a esto que se torna en una temática de alta importancia. Desde una cosmovisión social tiene consecuencias en la calidad de vida de la población y desde la perspectiva económica, costos de atención en salud. Algunas de las principales secuelas de las mismas, pueden derivar en afecciones del Sistema nervioso central y el esquelético-muscular; de manera que, ciertas estructuras determinantes para la preservación del equilibrio y la estabilidad en posición bípeda son deterioradas. Como es el caso de la **diabetes**

En términos de cifras la Organización Mundial de la Salud estima que anualmente se producen cerca de 37,3 millones de caídas de alta gravedad. Sumado a esto, anualmente fallecen cerca de 684.000 personas debido a lesiones de este estilo, esto se traduce en una ubicación en el segundo lugar de los principales causales de muertes por traumatismos involuntarios [14]. Justamente para el caso de complicaciones como la neuropatía diabética, se presentan daños en estructuras que comprometen la preservación de la estabilidad postural.

El punto focal de este proyecto hace parte de la línea de investigación de tecnologías emergentes en rehabilitación del grupo de investigación **BASPI-FootLab** y está dirigido a las personas que padecen de enfermedades crónicas como la diabetes y sufren de afecciones que comprometan la conservación de la estabilidad postural, y por lo tanto impliquen un riesgo de caída. Dicho grupo poblacional sufre de constantes situaciones de inestabilidad motora, y por ende caídas que pueden derivar en lesiones graves [15]. Estadísticamente, y tomando en cuenta lo estipulado por J.K. Richardson, C. Ching y E.A. Hurvits, los pacientes con neuropatía periférica tienen un riesgo de hasta veinte veces mayor, de sufrir una caída. [16]

1.2. Antecedentes y estado del arte

1.2.1. The Research in a Plantar Pressure Measuring System Connected with EEG

Este artículo introduce un sistema de medición de presión plantar en conjunto con el uso de tecnologías empleadas en el estudio de señales cerebrales, más precisamente EEG. Adicionalmente presenta a modo de cuantificación, la relación entre el ciclo de la marcha humana y las señales de EEG. Esta puede visualizarse claramente en el diagrama de bloques de esta solución en la figura 1. El proceso de estudio mostrado en dicho artículo deriva en tres fases fundamentales: inicialmente la adquisición de la señal EEG, como segunda medida la adquisición de la señal de aterrizaje del pie y finalmente la sincronización de los dos sistemas [1]. Si bien es un procedimiento ordenado y bien estructurado, además de establecer un buen punto de partida y guía para fines de este proyecto, la integración del sistema de presión plantar no realiza una clasificación y análisis por medio de métodos de aprendizaje de máquina.

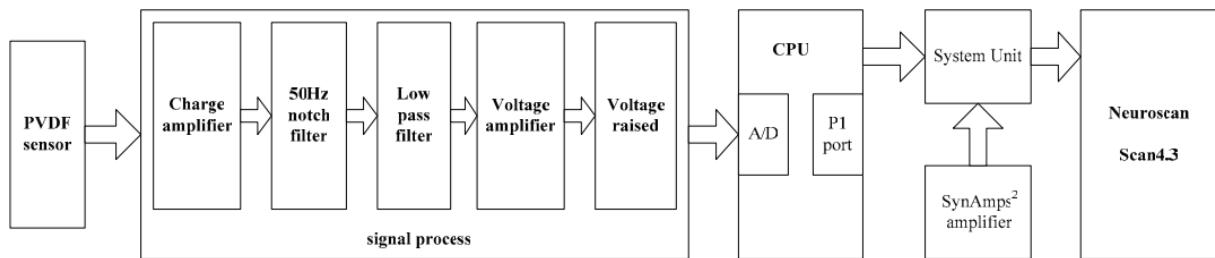


Figura 1: Diagrama de bloques, *medición de presión plantar*. Tomado de [1]

1.2.2. Real-Time Feedback of Body Center of Gravity for Postural Training of Elderly Patients with Peripheral Neuropathy

En este artículo se evidencia el funcionamiento y la construcción de un sistema que realiza estimaciones en tiempo real respecto a la ubicación del centro de gravedad del cuerpo humano. Sumado a ello, se tomaron muestras y se estableció un seguimiento de pacientes con **neuropatía diabética** de avanzada edad, en pruebas de inestabilidad postural generada mediante perturbaciones en una plataforma de apoyo; prestando especial atención al registro de caídas y preservaciones de estabilidad [17].

1.2.3. Postural stability analysis — A review of techniques and methods for human stability assessment

En este documento de conferencia, se hace una revisión de diversas técnicas para la evaluación de la estabilidad humana. Se revisa el balance humano en posturas estáticas mediante el procesamiento de imágenes en registros de video, en conjunto con métodos de sensores y plataformas para la medición de presión plantar. Sumado, se presentan varios protocolos y condiciones posturales para el registro de desplazamiento del centro de presión (CoP) [2].

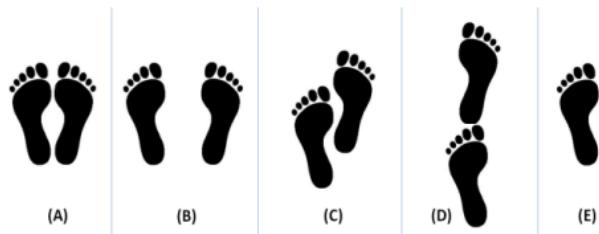


Figura 2: Posición de los pies en toma de datos con pacientes. Tomada de [2].

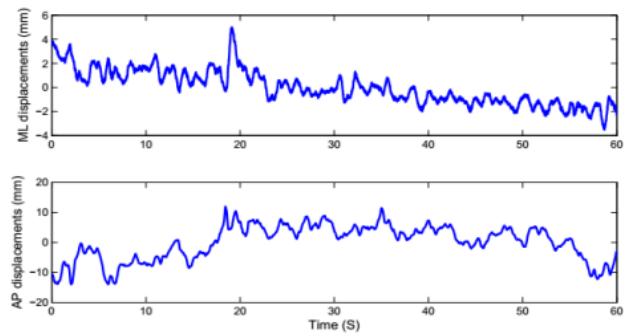


Figura 3: Desplazamiento mediolateral (arriba) y desplazamiento anteroposterior (abajo). Tomada de [2].

Este artículo presenta un claro marco de referencia para las imágenes de estabilometría (oscilación lateral y anteroposterior) que se esperaría obtener y la manera en que se esperan analizar las mismas en este proyecto.

1.2.4. PAPPI: Personalized analysis of plantar pressure images using statistical modelling and parametric mapping

El fundamento de este artículo en particular reside en una problemática puntual concerniente al estudio de señales y gráficas de podimetría y estabilidad. Esta responde a que el análisis de las mediciones de la presión plantar se encuentra ligeramente limitado en términos de individualización, tanto de los sujetos en los que son tomadas las pruebas como en cada uno de los pies. Esto puede deberse a que generalmente los análisis de presión plantar son realizados de manera grupal y desde presuposiciones de homogeneidad en los datos. Por lo que en ocasiones puede ser necesario recurrir a métodos más personalizados como lo pueden ser, justamente técnicas de modelado estadístico (como la presión media por áreas en el pie) y su mapeo paramétrico [18].

1.2.5. Estimation of the Center of Mass of Humanoid Robot

En este artículo de investigación se resalta inicialmente la importancia integral de un centro de control de la estabilidad, regulado a través de la información obtenida en los diferentes sistemas que posee el robot humanoide en cuestión, con el fin de mantener el equilibrio. No obstante, el punto focal del mismo corresponde a descripción detallada de la dinámica del desplazamiento en robots humanoides, usando modelo de péndulo invertido con longitud variable.

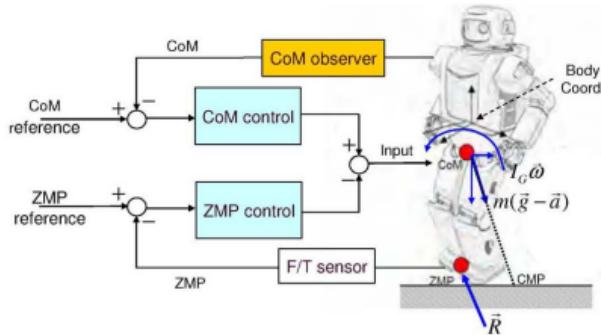


Figura 4: Diagrama de estimación del centro de masa de robot humanoide. Tomado de [3]

Adicionalmente ahonda en la explicación de un sistema de control de lazo, cerrado para aumentar la confiabilidad de las estimaciones del centro de masa del robot mediante la adopción del filtro discreto de Kalman. La principal utilidad de este documento responde a la comparativa en cuanto distribuciones de masa y facilidad de establecimiento del paralelismo de la geometría y el reparto de la masa en el robot humanoide, con la disposición biomecánica del sistema musculo-esquelético humano. [3].

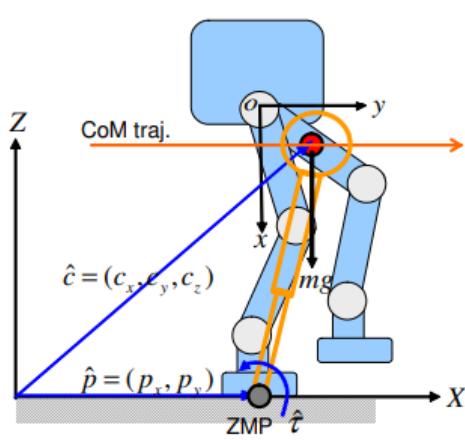


Figura 5: Modelado en péndulo invertido, robot humanoide. Tomada de [3].

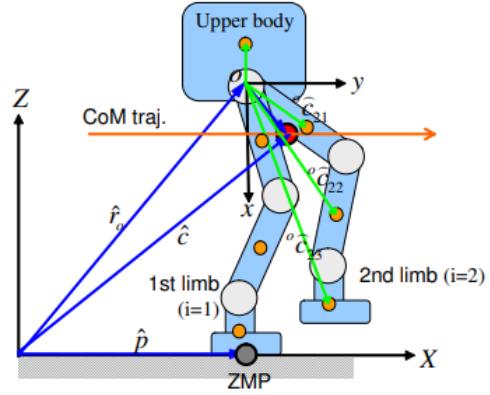


Figura 6: Despliegue de estimación del centro de masa, del humanoide teniendo en cuenta ángulos de distribución de peso. Tomada de [3].

1.2.6. Úlceras diabéticas y neuropáticas

Se recalca la importancia de la incidencia de la neuropatía diabética en los músculos del pie, el colapso del arco natural del mismo y de la misma manera, la generación de puntos anormales de presión. Esto por supuesto es una consecuencia directa de la pérdida de sensibilidad debido a la neuropatía misma y es algo que finalmente, repercute en el deterioro de la capacidad para preservar la estabilidad, tanto en posición bípeda como en la marcha [19]. Es recalca la importancia de la problemática y de la población a la cual va dirigido el proyecto.

1.2.7. EEG features during maintaining a human body balance

En la presente investigación se estudia el comportamiento humano al intentar mantener el equilibrio y la postura corporal. Todo desde el punto de vista de la caracterización de los rasgos comunes de la actividad cortical (actividad presente en la corteza cerebral) durante el control postural. Los resultados obtenidos a partir del estudio dan indicios claros de la localización de la actividad neuronal por cada banda de frecuencia, esto puede ser empleado como marcador neurofisiológico de la capacidad del sujeto frente al hecho de mantener el estado de equilibrio [4]. Adicionalmente, es útil como criterio de selección para los parámetros del filtro empleado y de la caracterización de los canales en frecuencia.

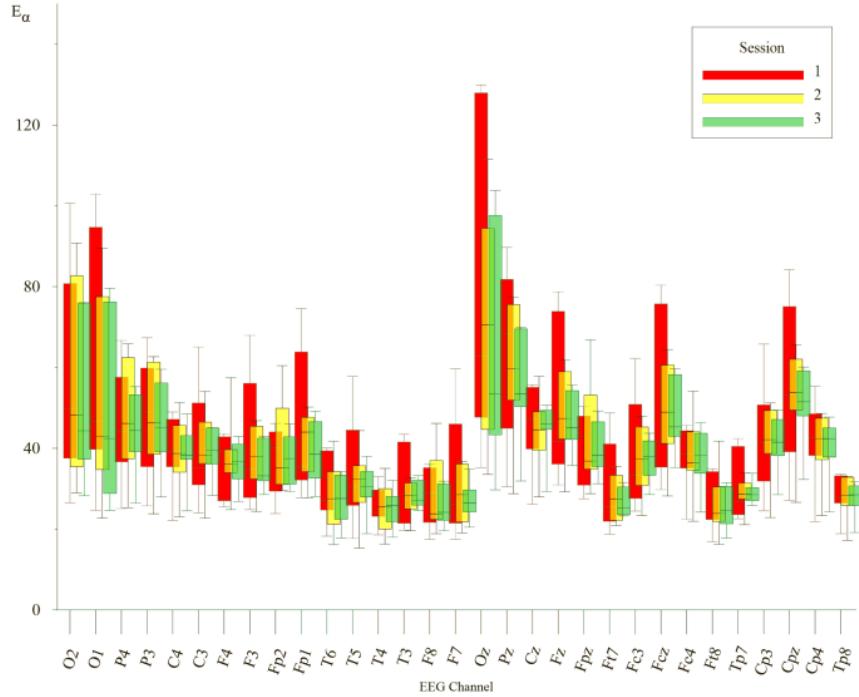


Figura 7: Caracterización espectral de canales EEG, en tres sesiones de toma de muestras. Tomado de [4]

1.2.8. Fabric-Based Wearable Dry Electrodes for Body Surface Biopotential Recording

Principalmente es evaluada la utilidad en el hecho de emplear electrodos secos en plataformas empleadas en la lectura de señales electroencefalográficas, frente a electrodos húmedos comerciales y sus limitaciones. Por lo que los primeros son postulados como posibles un fuerte competidor para la toma del registro de las señales de EEG. El principal objetivo de investigación es el contacto generado en la superficie piel-electrodo, a partir de diversos aspectos como el diseño de forma, la topología de colocación de cada uno de los electrodos del sistema. Adicionalmente se comparan, tanto las señales de ECG obtenidas con electrodos secos como los húmedos, en función de la postura y el movimiento del cuerpo [5].

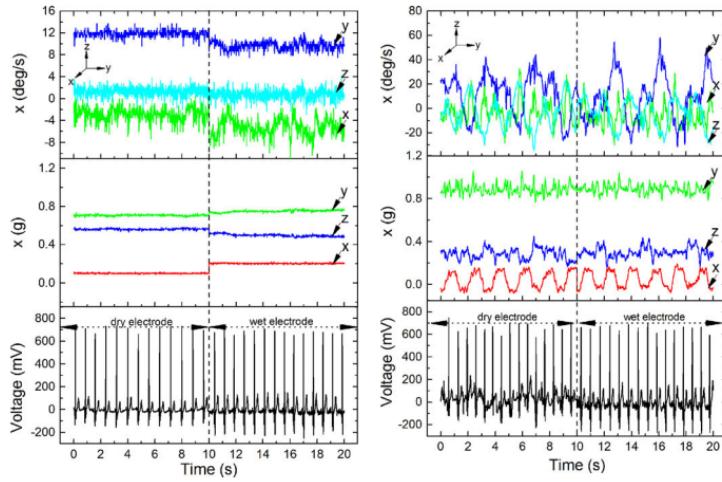


Figura 8: Comparativa entre señales tomadas con electrodos secos y electrodos húmedos, sentado vs en marcha respectivamente. Tomado de [5]

1.2.9. Specific movement detection in EEG signal using time-frequency Analysis

En este documento de conferencia, se precisa acerca de metodologías y configuración de parámetros recomendados en cuanto a la representación en escala de frecuencia para señales de electroencefalografía se refiere; además de servir como referencia para comprender algunos cambios bruscos relacionados con eventos en las señales asociados a patrones específicos de ritmos para el movimiento físico. Haciendo uso de una ventana de longitud predefinida, se establece una mejora en la identificación de frecuencias específicas dentro de la actividad cerebral, entre estas, las que corresponden a actividades musculares reales [6].

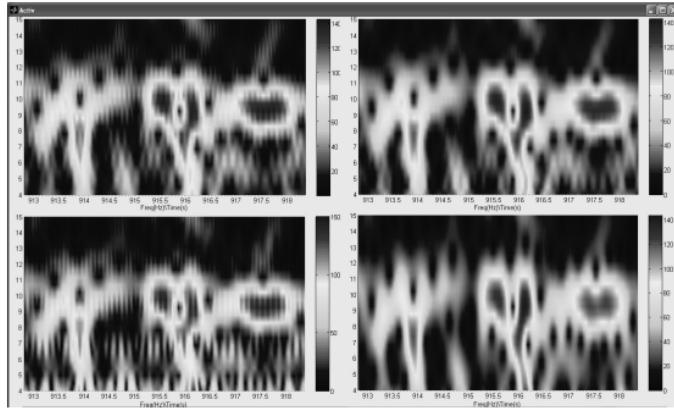


Figura 9: Misma señal EEG sometida a cuatro diferentes ventanas: Hamming, Hanning, Bartlett, Kaiser. Tomado de [6]

1.2.10. EEG Data Analysis:

En este notebook se hace uso de un conjunto de datos de entrenamiento que corresponde a señales cerebrales de voluntarios separados en dos grupos. Grupo de control y grupo alcohólico, ambos con 8 integrantes. Cabe resaltar que los datos fueron tomados con equipos compuestos por 64 electrodos, situados en el cuero cabelludo de los sujetos para medir la actividad eléctrica del cerebro. El conjunto

de datos en general, resulta útil en términos de comprender los rangos de trabajo para los valores de respuesta cerebral. Los cuales fueron muestrados a 256 Hz durante 1 segundo.

Cada sujeto fue expuesto a un solo estímulo (S1) o a dos estímulos (S1 y S2) que eran imágenes de objetos elegidos del conjunto de imágenes de Snodgrass y Vanderwart de 1980. Cuando se mostraban dos estímulos, se presentaban en una condición coincidente en la que S1 era idéntico a S2 o en una condición no coincidente en la que S1 difería de S2.”

Esto resulta sumamente conveniente en términos de comprender algunas respuestas esperadas para diferentes estímulos en la zona cortical.

Adicionalmente, fueron obtenidas mediante el uso de Google Colab, la siguiente gráfica:

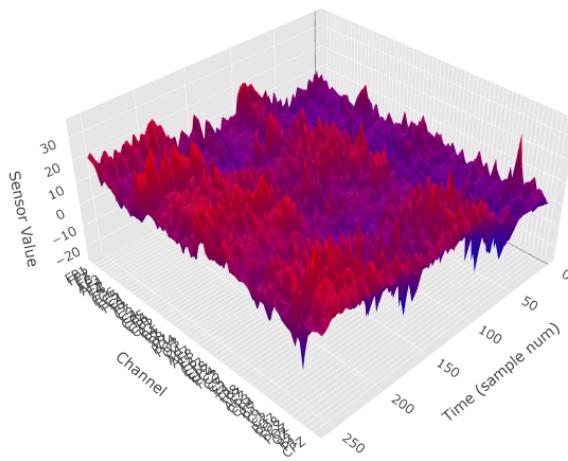


Figura 10: Gráfica datos EEG, obtenida mediante Google Colab

En este sentido, y posterior a la revisión de los antecedentes y el estado del arte, se establece una serie de consideraciones a tomar e implementar en este proyecto, como lo son las siguientes:

- La toma de datos de ambos sistemas, estabilometría y EEG de manera sincrónica.
- La utilización de técnicas de inteligencia artificial (ya sean algoritmos supervisados de clasificación o de regresión) para establecer una relación entre señales de presión plantar (estabilometría) y electroencefalografía.
- El análisis de señales de oscilación lateral y anteroposterior por separado e individualizado por cada voluntario.
- La importancia de comprender el comportamiento de los parámetros medidos a partir de la biomecánica en la preservación de la estabilidad postural.
- La caracterización individual por canales de EEG y en bandas específicas de interés.
- El uso de una medición con electrodos adecuadamente hidratados, con el fin de obtener señales más limpias (en términos de ruido e interferencia), lo cual facilitará el análisis.
- La aplicación de un filtrado y un análisis en frecuencia adecuados con el fin de esclarecer el estudio de las señales de EEG para la estabilidad postural.

2. Objetivos general y específicos

2.1. Objetivo general

- Diseñar e implementar un sistema para la medición de estabilidad postural, a partir del análisis y obtención de la relación entre el comportamiento de señales electroencefalográficas y señales de presión plantar.

2.2. Objetivos específicos

1. Adquirir una base datos referente a señales electroencefalográficas y de presión plantar adoptando, durante el proceso de toma de pruebas con pacientes, el protocolo establecido dentro del marco de los lineamientos de Footlab.
2. Realizar un procesamiento y normalización acorde con lo precisado en el caso particular del proyecto (de manera que se conserve una relación cuantitativa con lo investigado en el estado del arte), para el tratamiento y selección de las señales requeridas.
3. Implementar al menos dos métodos de aprendizaje de máquina empleados en la estimación de la estabilidad postural, encontrando una relación entre el comportamiento de señales electroencefalográficas y señales de presión plantar.
4. Evaluar el desempeño del análisis de relación realizado entre los dos sistemas de medición por medio de los métodos de aprendizaje de máquina implementados.

3. Requerimientos del cliente

Fueron propuestos los requerimientos mencionados a continuación, y divididos en funcionales y no funcionales:

■ Requerimientos funcionales:

- Hacer uso del sistema Emotiv EPOC + y la plataforma de presión plantar suministrada por el laboratorio de Footlab.
- El análisis de las señales corticales debe mostrar una clara correspondencia con los patrones específicos esperados.
- Tomar un registro por una ventana de tiempo no mayor a 6 minutos durante la toma de datos con pacientes.
- Identificar las áreas del cerebro que son estimuladas en la conservación de la estabilidad postural.

■ Requerimientos no funcionales:

- Los datos adquiridos, deben ser procesados y analizados en el computador de escritorio suministrado por el laboratorio de electrónica de la Pontificia Universidad Javeriana. Tal que, dichos datos no podrán ser empleados ni analizados fuera del campus, y para fines diferentes del proyecto.
- Los datos adquiridos deberán ser anonimizados de acuerdo a normativas de protección de datos personales.
- Realizar una toma de muestras con pacientes bajo el marco de legalidad y los protocolos bioéticos de Footlab.

- El sistema debe funcionar en una plataforma computacional.
- Las implementaciones de los métodos de aprendizaje de máquina deben realizarse en lenguaje Python.

4. Estándares

A continuación, se presentan los estándares en ingeniería y bioética, pertinentes para la realización este proyecto:

1. **1633-2016 - IEEE Recommended Practice on Software Reliability** [20]. El propósito del estándar es presentar un marco de evaluación para la confiabilidad de determinado software, teniendo en cuenta, principalmente si el software ha cumplido con un objetivo de confiabilidad previamente establecido y garantizando la calidad del producto.

2. **1012-2016 - IEEE Standard for System, Software, and Hardware Verification and Validation** [21]

El propósito central de este estándar es establecer un marco común para los procesos de validación y verificación de actividades y tareas en relación a los procesos del software y hardware. Se definen tareas de validación y verificación, entradas y salidas requeridas en cada proceso.

3. **Ley 23 de 1981 – Relaciones médico – paciente** [22]

Principalmente en los artículos 14, 15 y 18. En los cuales se advierte la necesidad del consentimiento, para realizar los diferentes tratamientos médicos requeridos. Lo que se busca cumplir al implementar este estándar es realizar todos los procedimientos de toma de datos con pacientes dentro del marco de la legalidad y los debidos protocolos bioéticos.

4. **Norma EN 60601-1 - BSI** [23]

Desde un punto de vista general, esta norma abarca temas de bioseguridad y fiabilidad de equipos electrónicos que, dentro del ámbito médico entran en contacto directo con los pacientes. Al incluir este estandar, se asegura la confiabilidad de ambos dispositivos empleados en la toma de datos con voluntarios (Emotiv Eloc + y Plataforma de presión plantar ECOWALK)

5. **ISO 27001: 2013 Sistemas de Gestión de la Seguridad de la Información** [24]

Esta es una norma que asegura la confidencialidad, tanto de los datos como de los equipos empleados para su procesamiento y tratamiento. De esta manera, los datos de todos y cada uno de los voluntarios fueron únicamente procesados y tratados en el puesto de trabajo designado por el laboratorio de Footlab.

6. **Ley 1581 de 2012 - Ley de Protección de Datos Personales**

“Reconoce y protege el derecho que tienen todas las personas a conocer, actualizar y rectificar las informaciones que se hayan recogido sobre ellas en bases de datos o archivos que sean susceptibles de tratamiento por entidades de naturaleza pública o privada.” [25]

5. Marco teórico

5.1. Equilibrio y centro de masa

El equilibrio biológico es definido comúnmente como homeostasis, del griego: “homos” que significa similar y “stasis” que quiere decir estado. La estabilidad hace referencia a un cuerpo, que mantiene

sus condiciones a pesar de las perturbaciones; de manera que, experimenta pocos cambios.

Ahora bien, balance es definido como la capacidad de todo ser humano para mantenerse en pie, y desde el punto de vista de la biomecánica, es el control continuo del desplazamiento del centro de masa. Teniendo este contexto, es tomado como eje “y” la columna vertebral y el punto de contacto al encontrarse en posición bípeda, está representada por la interacción de la superficie de los pies. Particularmente en esta posición, el centro de masa de la persona adquiere una localización cercana a la segunda vértebra sacra (S2). Dicha ubicación varía de acuerdo a los cambios de la postura corporal. La importancia de tener correctamente indicado este punto, reside en conocer el lugar donde se reúnen los vectores de fuerza. Esto corresponde con la preservación del equilibrio estático.

Desde una perspectiva experimental, y de acuerdo con Ge Wu [17] el centro de masa del cuerpo humano puede ser visualizado y modelado por medio de ecuaciones mecánicas, con la finalidad de realizar un análisis de las fuerzas externas que actúan al momento de mantener el equilibrio. En física mecánica, la sumatoria de todas las fuerzas externas que actúan sobre un cuerpo y todos los momentos de fuerza incidentes en el mismo deben ser iguales a cero para que este se encuentre en estado de equilibrio. Bajo las condiciones anteriormente mencionadas, un cuerpo puede únicamente encontrarse en estado estable o inestable, o lo que es lo mismo, en equilibrio o desequilibrio. De esta manera, se realiza el despliegue en ecuaciones trigonométricas referente a la ubicación del centro de masa en un cuerpo humano ubicado en postura bípeda y sobre una plataforma:

$$\begin{aligned} X_{CoM} &= L_1 \cos(\alpha + \beta) - L_2 \cos(\alpha + \beta + \gamma) - L_3 \sin(\alpha + \beta + \gamma) \\ X_1 &= L_1 \cos(\alpha) \\ X_h &= -L_h \cos(\alpha) \end{aligned}$$

Donde, X_{CoM} corresponde a la localización del centro de masa, α es el ángulo de la plataforma, β corresponde con los ángulos de libertad del tobillo y γ el ángulo de la cadera respecto al torso. L_1, L_2 y L_3 , son la distancia desde el tobillo hasta la cadera, la distancia vertical desde la cadera al centro de masa y finalmente la distancia horizontal desde la cadera al centro de masa, respectivamente. No obstante, resulta importante recalcar que la posición bípeda resulta una condición viable para el estudio de las variables involucradas en el control postural, dado que hay implícitamente involucrados, movimientos de oscilación producidos a raíz del control del centro de presión de los seres humanos. [26]. Esto implica que por pequeñas que sean, siempre existirán compensaciones involuntarias en condiciones de equilibrio aparente. [27]

5.2. Parámetros presentes en la conservación del equilibrio

5.2.1. Centro de presión (COP):

Por sus siglas en inglés *center of pressure*, corresponde al punto de proyección en el se concentran todos los vectores de fuerzas verticales durante la marcha o en posición estática sobre determinada base de sustentación y donde también coincide el centro de masa. [27] El desplazamiento del mismo a lo largo del tiempo es normalmente representado mediante gráficas de movimiento lateral y anteroposterior, así como sus correspondientes baricentros (individualmente para cada pie y central). [27]

5.2.2. Base de sustentación

Se refiere al área debajo de todo ser humano, que incluye todos los puntos de contacto entre sus pies y la superficie de apoyo. Una amplia base de sustentación esta normalmente asociada como indicativo de una marcha inestable, y por lo tanto con una mayor frecuencia de caída una característica que se hace mas notoria con el aumento de edad y principalmente en adultos mayores. [28]

5.3. Estabilometría

Corresponde al estudio del control postural estimando el movimiento del centro de presión (en términos de series de tiempo), y de esta manera, estableciendo una relación con la estabilidad. De acuerdo a la capacidad de procesamiento de plataforma empleada para su medición, la estimación anteriormente mencionada, puede darse en diversas posturas como lo pueden ser: posición bípeda, postura *tandem*, en un solo pie, etc. En el caso de la posición bípeda, las gráficas obtenidas, surgen a partir de la información sensorial tomada de la dinámica muscular de las fibras que rodean a ambos tobillos. Esto ocurre debido a las compensaciones de balance del individuo. [28] [26] La evaluación estabilométrica permite la visualización y análisis de las pequeñas variaciones de desplazamiento del COP concerniente a oscilaciones antero-posteriores y laterales. El registro es realizado mediante el cálculo de su posición en las coordenadas X y Y, que corresponden a la localización resultante de las fuerzas aplicadas en la superficie en contacto con los pies:

$$CoP_{(x,y)} = (a_x, a_y)$$

$$a_x = \frac{d_1[f_1 + f_2 - f_3 - \dots - f_n]}{mg}$$

$$a_y = \frac{d_2[f_1 + f_2 - f_3 - \dots - f_n]}{mg}$$

5.4. Electroencefalografía

Acuñado como concepto en 1929 por Hans Berger, es un método empleado en el registro de actividad cerebral de tipo no invasivo ya que se usan electrodos extracraneales, situados específicamente sobre el cuero cabelludo. Tiene aplicaciones en campos como estudio del sueño, entrenamiento de interfaz cerebro máquina (BCI), estudio de ataques epilépticos, estados psíquicos, etc. Las señales de EEG son generadas a partir de corrientes de naturaleza iónica, a su vez ocasionadas por dinámicas de tipo neuronal (sinapsis) [29]. Para poder ser registradas, estas corrientes iónicas pasan por un proceso de conversión a eléctricas (por medio de diferencia de potencial entre potenciales de acción en la transmisión sináptica).

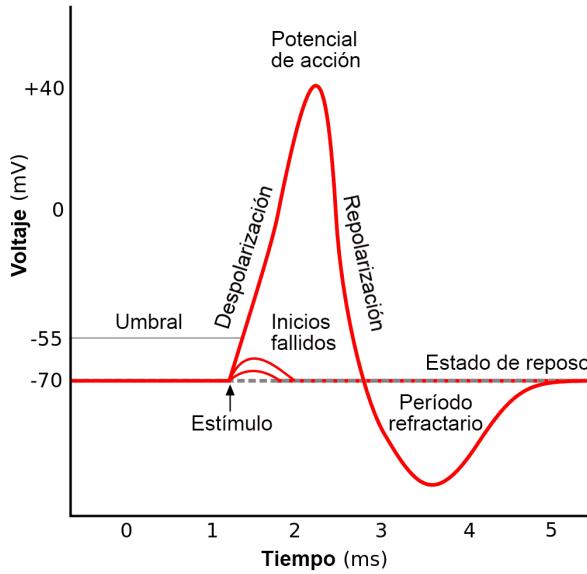


Figura 11: Potencial de acción. Tomado de [7]

Fundamentalmente a la electroencefalografía le compete el estudio de polaridad y valoración de parámetros como amplitud voltaje a lo largo del tiempo, densidadpectral, frecuencia, etc. En la generalidad de los casos, las ondas obtenidas por cada toma son de amplitudes bastante reducidas (entre 10 y 100 μ V) y se encuentran separados en las siguientes bandas de frecuencia:

Bandas de frecuencia de EEG	
Denominación de la banda	Frecuencia
<i>Delta</i>	1-3Hz
<i>Theta</i>	3.1-7.9Hz
<i>Alpha</i>	8-13 Hz
<i>Beta</i>	14-29Hz
<i>Gamma</i>	30-100Hz

Cuadro 1: Bandas de frecuencia de electroencefalografía

La manera de registro de estas señales, como se mencionó anteriormente corresponde al uso de electrodos, más específicamente **macroelectrodos**. Estos están diseñados para realizar lecturas de potenciales post-sinápticos de millones de neuronas situadas bajo el área de dicho electrodo.

5.5. Áreas de Brodmann

Como es bien sabido, el cerebro es un órgano cuya importancia reside en ser el principal componente del sistema nervioso humano, dado que recibe y emite todos los impulsos de los sentidos por medio de la médula espinal, además de gestionar procesos más complejos como las emociones, dinámicas de memoria y pensamientos. Labores que son solventadas gracias a la interacción ordenada entre más de 100 mil millones de células cuyo funcionamiento a altas velocidades se basa en excitaciones iónicas por medio de lo que se conoce como sinapsis, las neuronas. De acuerdo a su funcionalidad, el cerebro puede dividirse morfológicamente en 50 zonas encargadas de labores específicas, tal y como lo estipuló el anatómico alemán Korbinian Brodmann [30], como se muestra a continuación:

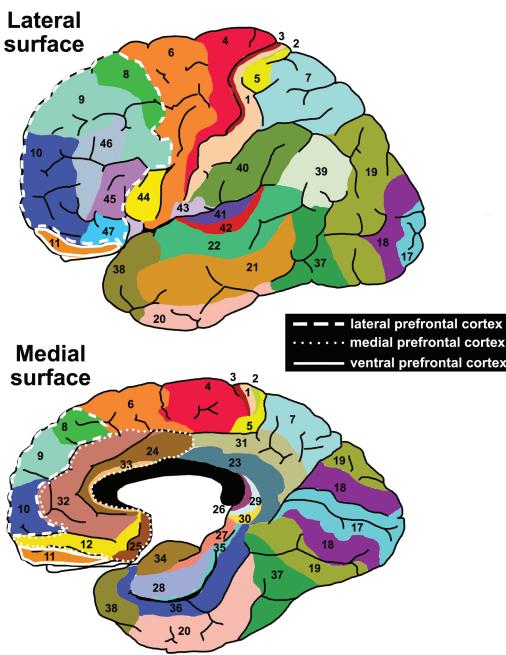


Figura 12: Áreas de Brodmann. Tomado de [8]

Esta clasificación característica está dada por diferencias, como la estructura de la corteza y la localización misma. Principalmente, las áreas de interés a lo largo de este proyecto fueron las siguientes:

- **Área 4: Corteza motora primaria** Ubicada en circunvolución frontal ascendente y cuya funcionalidad está asociada al control de los movimientos voluntarios.
- **Área 5: Corteza sensitiva somática de orden elevado** Ubicada en el lóbulo parietal superior y asociada a la estereognosia, es decir la orientación espacial y percepción.
- **Área 6: Corteza motora complementaria** Ubicada en la circunvolución frontal ascendente y corteza rostral adyacente, asociada a la planificación de los movimientos oculares y de las extremidades.
- **Área 7: Asociación parietal posterior** Ubicada en el lóbulo parietal superior, asociada a la percepción visual motora y la conciencia espacial.
- **Área 19: Corteza visual de orden elevado, área visual temporal media** Situada en la circunvolución occipital medial y lateral, asociada a las funcionalidades de visión, color, movimientos y profundidad.
- **Áreas 41 y 42: Cortezas auditiva primaria y auditiva secundaria, respectivamente** Ubicadas en las circunvoluciones temporales transversas y circunvolución temporal superior. Directamente relacionadas con el funcionamiento del oído.

5.6. Sistemas que intervienen en el equilibrio biológico

Principalmente, el ser humano regula el equilibrio y es capaz de restablecerlo ante diferentes perturbaciones mediante tres sistemas:

- Sistema vestibular:** Las diferentes funcionalidades que proporcionan las diferentes estructuras que se encuentran ubicadas en el oído interno, es aquello que se denomina como aparato vestibular. De acuerdo a la colocación y disposición del cráneo, se generan diferentes dinámicas que posibilitan el movimiento de la endolinfa, el líquido que se haya circulando por el laberinto membranoso [31].

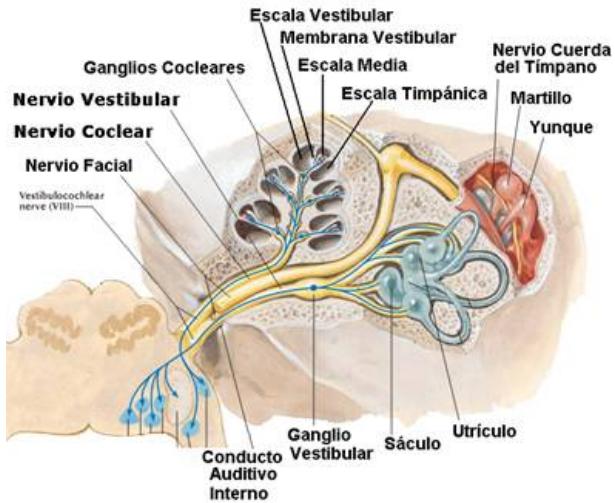


Figura 13: Oído interno. Tomado de [9]

En el interior del laberinto membranoso, se sitúan la cóclea y unidades sensoriales que facilitan el equilibrio [10]. Estos receptores corresponden a células pilosas denominadas como estereocilios, las cuales están encargadas de sensar toda la información referente a la dirección de movimiento y los cambios fisiológicos de posición. La funcionalidad de este sistema, con fines prácticos, podría ser descrita de manera muy similar a la forma en que funciona un acelerómetro.

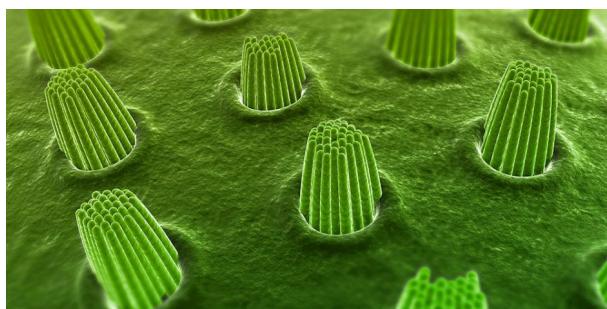


Figura 14: Cílios. Tomado de [10]

- Visión:** El grado de importancia de este sistema es imprescindible, dado que permite percibir el entorno en términos de ubicación y de cercanía de los objetos. Mediante contracciones musculares y haciendo uso de la córnea y el cristalino, el ojo adquiere la capacidad de enfocar la luz del ambiente observado a través de la retina. El funcionamiento del iris se asemeja al del diafragma de una cámara fotográfica, debido a que está en capacidad de aumentar o disminuir el diámetro de su abertura con la finalidad de filtrar la luz [11].

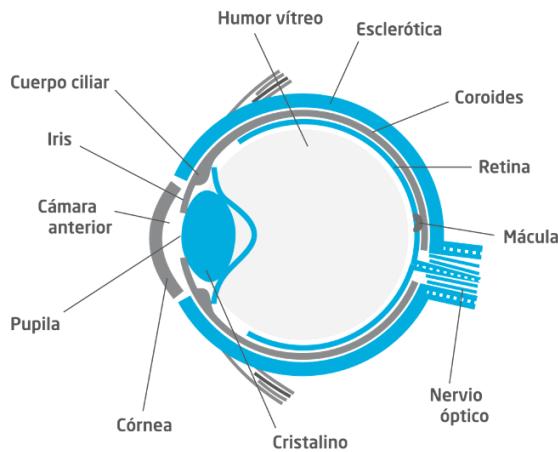


Figura 15: Partes del ojo. Tomado de [11]

3. **Sistema propioceptivo:** Distribuido por el torso, extremidades superiores e inferiores, donde se ubican sensores encargados de transmitir impulsos eléctricos al cerebro para indicarle estímulos adicionales del entorno. Estos receptores comprenden diversas sensaciones obtenidas mediante el tacto, como lo pueden ser los cambios de temperatura y de presión. Dichos estímulos están a cargo de terminaciones nerviosas dendríticas de diferentes neuronas sensoriales. [12]

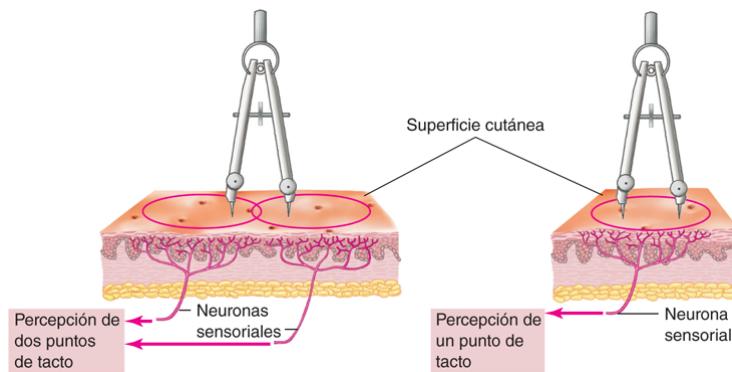


Figura 16: Tacto. Tomado de [12]

5.7. Filtro digital

Es un sistema empleado para atenuar o amplificar (según sea el caso), señales digitales en el dominio de la frecuencia. Generalmente usado en situaciones en las que se requiere separar la mezcla de varias señales, recuperar señales distorsionadas. El desempeño de un filtro está dado por su función de transferencia

$$H(z) = \frac{B(z)}{A(z)} = \frac{b_0 + b_1 z^{-1} + b_2 z^{-2} + \dots + b_N z^{-N}}{1 + a_1 z^{-1} + a_2 z^{-2} + \dots + a_M z^{-M}}$$

Figura 17: Función de transferencia de un filtro digital

5.8. Transformada de Wavelet Discreta

La electroencefalografía corresponde a una exploración medible de toda la actividad eléctrica cerebral, con la finalidad de comprender señales referentes al adecuado o inadecuado funcionamiento de cada uno de los procesos fisiológicos [32]. En esta situación puntual en la que se requiere la extracción de características particulares visualizadas a manera de señales de tipo cortical (localizadas en la corteza cerebral), puede llegar a ser afectada por ruido en bandas tanto de alta, como de baja frecuencia [13]. Entre estas, se pueden encontrar principalmente el ruido de línea, otras señales concernientes a diversas dinámicas de tipo muscular (especialmente ligadas a frecuencias altas más referentes a electromiografía).

Justamente en este punto, se requiere de la utilización de un método de Wavelet para la eliminación de las bandas de frecuencias no deseadas [33]. De acuerdo a Heydari y Shahbakhti esta técnica llega a ser sumamente efectiva, dado que llega a tener un rendimiento comparable a la de un Butterworth de cuarto orden [13]. Como en el caso de otros análisis de tipo matemático para el procesamiento de señales, Wavelet descompone la señal en diferentes componentes de frecuencia para de esta manera facilitar la exploración de cada una de sus partes.

Desde el análisis netamente discreto, la transformada descompone la señal en un conjunto de señales en términos de versiones trasladadas y dilatadas de la misma (lo que se conoce como ondículas) mutuamente ortogonales.

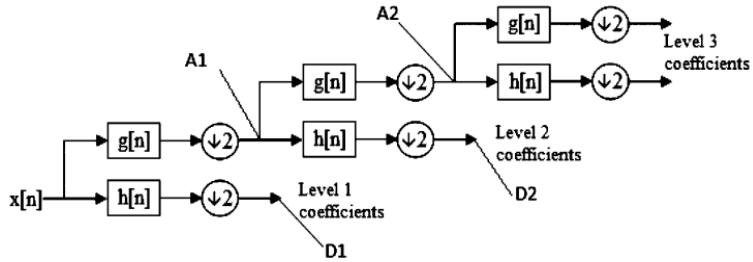


Figura 18: Estructura de la transformada discreta de Wavelet. Tomado de [13]

Donde h y g son filtros pasa altas y pasa bajos respectivamente y $\downarrow 2$ corresponde a un *submuestreo*. En este sentido, la salida del sistema corresponde a:

$$A_{j+1}[p] = \sum_{n=-\infty}^{+\infty} g[n-2p]a_j[n]$$

$$D_{j+1}[p] = \sum_{n=-\infty}^{+\infty} h[n-2p]a_j[n]$$

Siendo A_j el coeficiente de aproximación, y D_j el coeficiente de detalle que determina la salida de la transformada.

5.9. Transformada de Welch

Las señales de electroencefalografía pueden estudiarse individualmente y obtener características haciendo uso de las componentes de densidad espectral de potencia (PSD). La densidad espectral, indica cómo se distribuye la potencia de determinado canal de EEG en el dominio de la frecuencia (periodograma). Es pues, el método de Welch, uno de los métodos de análisis de densidad espectral

de potencia que más facilitan el estudio de diferentes señales biológicas, ya que caracteriza las señales de manera que la distinción entre bandas de frecuencia se más fácil de visualizar. [34]
El método reduce el ruido en los espectros de potencia a cambio de reducir la resolución de frecuencia. Matemáticamente, surge como una modificación al método de Barlett; el cual también es un estimador del espectro de potencia usando periodogramas. Teniendo una señal con muestras $x(n)$ no dependientes entre sí (incoreladas) de longitud L , el periodograma de la misma es:

$$S_{per}(e^{jw}) = \frac{1}{L} \left| \sum_{n=0}^{L-1} x_i(n) e^{-jnw} \right|^2 ; n = 1, 2, \dots, k$$

El promedio de todos los periodogramas, corresponde al estimador de Barlett:

$$\hat{S}_{per}(e^{jw}) = \frac{1}{k} \sum_{i=1}^k \hat{S}_{per}^i(e^{jw})$$

Entre algunas de las modificaciones al método Barlett, Welch propuso inicialmente, el solapamiento de segmentos de datos. [35]. Suponiendo que entre dos secuencias sucesivas de longitud L , hay desplazamiento de D puntos, la secuencia i -ésima está dada por:

$$x_i(n) = x(n + iD) ; n = 0, 1, \dots, L - 1$$

El solapamiento del 50 % de dos secuencias consecutivas $x_i(n) + x_{i+1}(n)$ es de $L-D$ puntos, para K secuencias de N puntos cada una:

$$K = \frac{2N}{L - 1}$$

De esta manera, la longitud de la secuencia (resolución) no varía, pero se reduce la varianza al doblar el número de periodogramas. Como segunda medida, se enventana cada secuencia $x_i(n)$ con una ventana general $w(n)$, de manera que se obtiene un periodograma similar al de Barlett modificado:

$$\hat{S}_M(e^{jw}) = \frac{1}{LU} \left| \sum_{n=0}^{L-1} w(n) x_i(n) e^{-jnw} \right|^2$$

Donde U corresponde a:

$$U = \frac{1}{L} \sum_{n=0}^{L-1} |w(n)|^2$$

Teniendo esto, el estimador de Welch es el promedio de periodogramas como el anterior. Obteniendo como expresión general:

$$\hat{S}_w(e^{jw}) = \frac{1}{KLU} \sum_{i=0}^{k-1} \left| \sum_{n=0}^{L-1} w(n) x(n + iD) e^{-jnw} \right|^2$$

A continuación, se presenta el ejemplo de un periodograma de Welch correspondiente a una señal coseno, realizado en Matlab y haciendo uso de la librería *pwelch*:

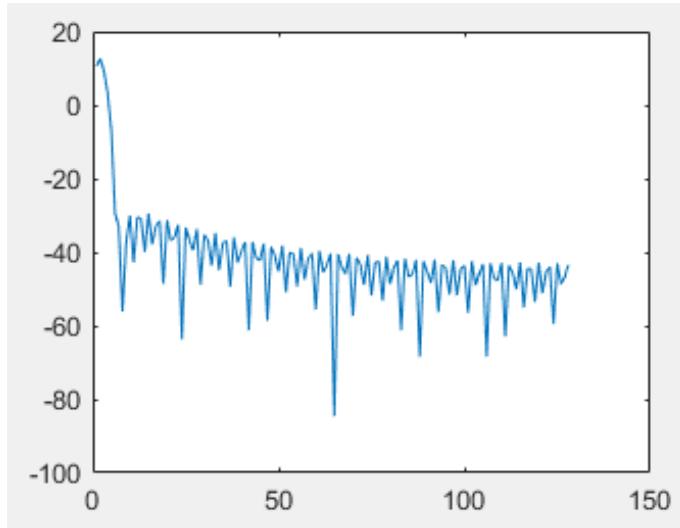


Figura 19: Periodograma de Welch de señal coseno en Matlab

6. Metodología

La completa realización del proyecto estuvo sujeta a la metodología de trabajo CDIO [36]. Esta está basada en la consecución de etapas de concepción, diseño, implementación y operación; todo con miras a la resolución de la problemática brindada por un cliente determinado.

6.1. Diagrama de bloques

La solución propuesta de este proyecto está organizada en entidades o bloques y se fundamenta en etapas características que corresponden a: fase de adquisición de las señales, fase de procesamiento, fase de extracción de características y finalmente clasificación de señales. A continuación se presenta el diagrama de bloques:

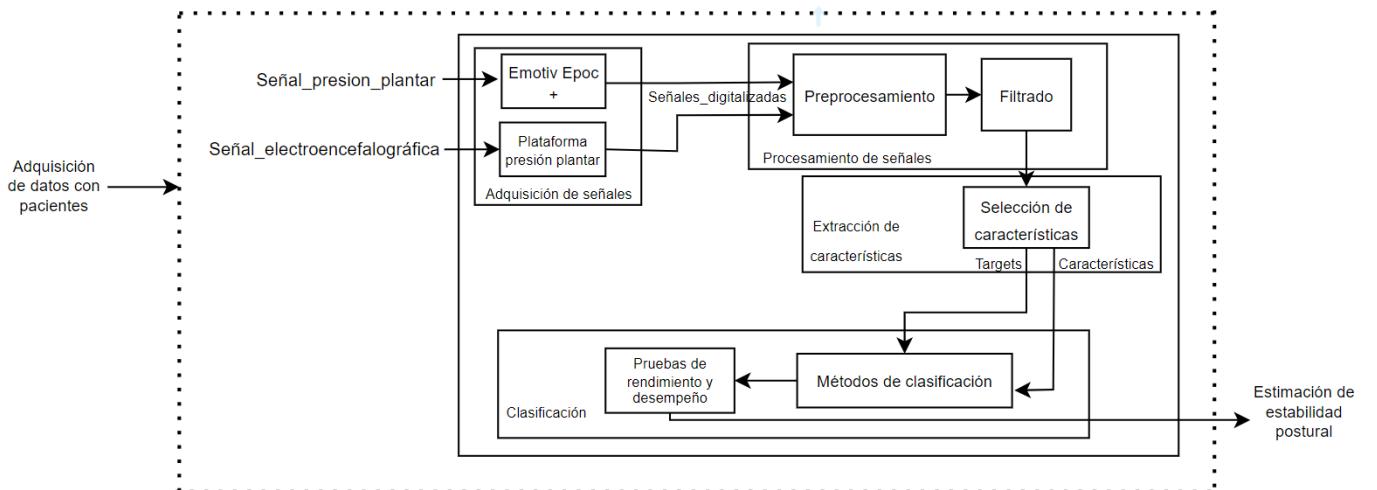


Figura 20: Diagrama de bloques de la solución propuesta

6.2. Protocolo de toma de datos

En este punto fueron definidos todos los procedimientos que serían llevados a cabo con cada uno de los voluntarios, para la adquisición de una base de datos propia. Todo siguiendo los lineamientos éticos y legales debidos frente al tratamiento de datos personales y dentro de lo enmarcado de por los protocolos del grupo de investigación **BASPI - Footlab**. Para ello fue necesaria la revisión en la literatura, tanto de los estándares de manejo de datos, como de protocolos empleados en la valoración de la estabilidad postural. En este punto, es determinante mencionar que justamente, por políticas de confidencialidad de la Pontificia Universidad Javeriana, los datos fueron adquiridos en una máquina física, situada dentro del laboratorio de Footlab y procesados en el mismo ordenador, haciendo uso de un local host trabajado a manera de *Notebook*. Para mayor detalle en cuanto a la selección de las posturas de la toma de datos, así como política de tratamiento y criterios de inclusión o exclusión se refiere, ver: Anexo 1. Protocolo de toma de datos con voluntarios (EEG y presión plantar)¹.



Figura 21: Toma de datos sincrónica de estabilometría y EEG

6.3. Registro de electroencefalografía:

Para los datos de electroencefalografía se hizo necesaria la utilización del equipo EMOTIV EPOC+. Un **headset** que consta de 14 electrodos superficiales, de funcionamiento húmedo y distribuidos por

¹Es importante recalcar que tanto el procedimiento de toma de datos de electroencefalografía, como la toma de datos de estabilometría fueron realizados de manera **sincrónica**, es decir en una misma ventana de tiempo, cuya longitud fue de 60 segundos.

zonas generales de la corteza cerebral: Frontal, Anterior-Frontal, Frontal-Central, Temporal, Parietal y Occipital. No obstante, esta distribución está sujeta al sistema internacional 10-20, basado en la relación entre la ubicación de los electrodos y el área cortical correspondiente. [37]



Figura 22: Emotiv Epoc+

Adicionalmente y de acuerdo a este sistema, la denominación numérica de los electrodos responde el hemisferio por el que se encuentran repartidos. En el caso particular del Emotiv EPOC + los electrodos: AF3, F7, F3, FC5, T7, P7 y O1 poseen las iniciales de la zona cortical a la que están asociados, y al ser impares se encuentran en el hemisferio izquierdo del cerebro. Por su parte, los electrodos: O2, P8, T8, FC6, F4, F8 y AF4 se hallan al lado derecho del cerebro. Tal y como se muestra en la siguiente figura:

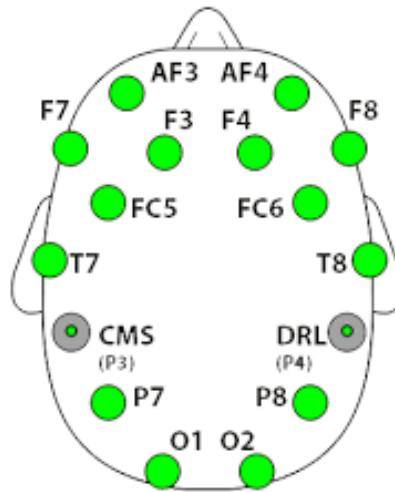


Figura 23: Disposición de los electrodos del Emotiv Epoc+

A continuación son descritos los pasos llevados a cabo en el protocolo de toma de datos de electroencefalografía:

- Inicialmente, fue necesario hidratar todos los electrodos del headset correspondiente haciendo uso de una solución salina. En este caso en particular se dispuso de la solución multipropósito de marca **Re-nu**, ya que el fabricante del dispositivo recomienda una solución salina entre 0,7 % y 4 % soluto/peso de cloruro de sodio, y una cantidad menor al 4 % por volumen, de un desinfectante doméstico como alcohol isopropílico al 70 %. [38]
- Como segunda medida, se ejecuta la interfaz gráfica de usuario proporcionada por EMOTIV (EMOTIV Launcher), para la visualización previa y exportación de los datos. Lo primero que

se observa al abrir la interfaz y conectar el Epoch+ vía *bluetooth* es el estado de la batería del dispositivo y el porcentaje de calidad de contacto, como se muestra a continuación:

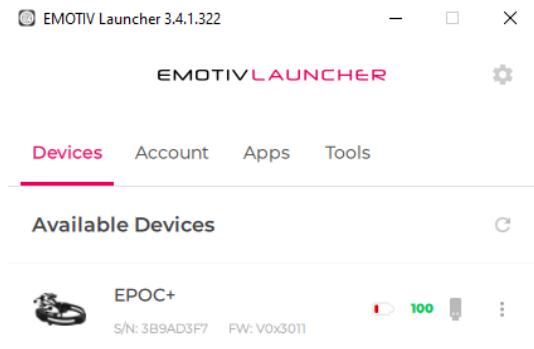


Figura 24: Batería y conectividad del Emotiv Epoch+

- El paso subsecuente corresponde a verificar la calidad de contacto de los 14 electrodos del headset, lo cual depende fundamentalmente de dos factores: del estado de carga de la batería y el nivel de hidratación de los electrodos.

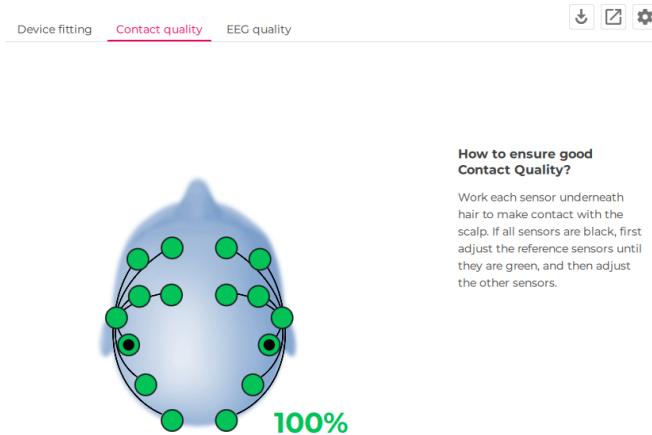


Figura 25: Calidad de contacto de los electrodos

- Posteriormente se procede a verificar la calidad de las señales de EEG. Este punto es **fundamental** para asegurar una toma de datos exitosa en términos de fidelidad de los datos y la obtención de canales poco afectados por el ruido. Este punto está correlacionado con el anterior, y con una correcta disposición de los electrodos en las zonas predilectas (Frontal, Anterior-Frontal, Frontal-Central, Parietal, Temporal y Occipital).

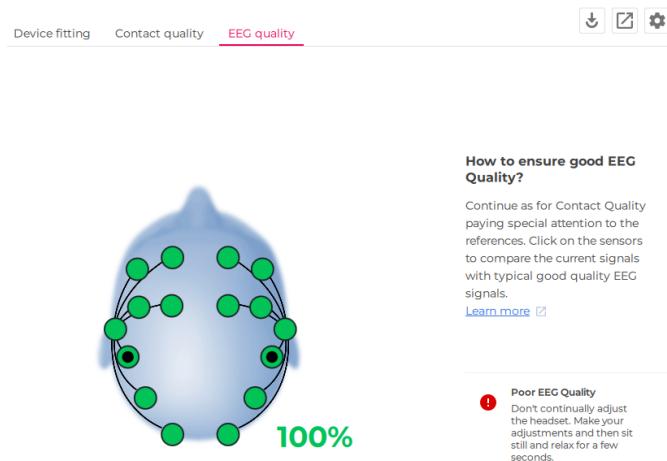


Figura 26: Calidad de las señales de EEG

- Ahora bien, si las calidades de contacto y de las señales de EEG fueron del 100 %, lo esperado es la visualización de los 14 canales sin ruido aparente y con dinámica de **blink** cada vez que el usuario parpadee [39]:

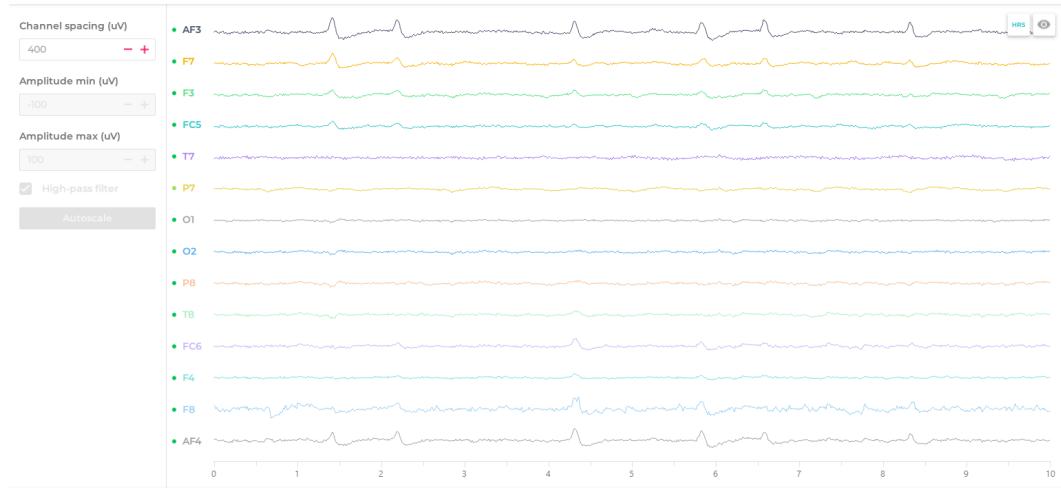


Figura 27: Dinámica de parpadeo en canales del EpoC+ - Voltaje vs Tiempo

- Finalmente, el paso restante corresponde a seleccionar un formato adecuado para la exportación de las señales en tiempo, por lo cual fue seleccionada la extensión de archivo de texto separado por comas **.csv**; como contrapartida el formato elegido para guardar los nombres de archivo fue el siguiente:

000_A_B_OjosEstado_Toma_x

Donde “**000**” corresponde al código del voluntario otorgado por el laboratorio al inicio del protocolo de toma de datos, “**A y B**” corresponden a las iniciales del primer nombre, y el primer apellido respectivamente, “**Estado**” corresponde a ojos abiertos/cerrados, según sea el caso, y finalmente “**x**” corresponde al número de toma².

²Fue requerido el registro de un nuevo usuario y el pago de una licencia EMOTIV PRO, con el fin de posibilitar la extracción los datos de EEG de la interfaz gráfica de usuario.

6.4. Registro de estabilometría y presión plantar

En el caso del registro de los datos de electroencefalografía se hizo uso de la plataforma *Ecowalk*, con una tasa de muestreo de 30Hz, provista de 2304 sensores en un arreglo de 48x48, es decir 1 sensor por cm^2 . [40] Este artefacto permite obtener:

- Gráficas presión plantar, vistos a manera de mapas de bits.
- Series en tiempo para oscilaciones lateral y anteroposterior, haciendo uso del centro de presión (COP).
- Baricentros de presión, directamente ligados con las oscilaciones de COP.
- Distribución media de presión por pie.

La toma de datos fue realizada orientando a cada uno de los voluntarios para que se situaran descalzos sobre la plataforma de presión plantar, en posición bípeda. La sucesión de pasos para el registro de cada una de las tomas que se siguió, se describe a continuación:

- Inicialmente se verifica la conexión de la plataforma con el computador que almacenará la base de datos. Luego de ello, dentro de la interfaz gráfica de *Ecofoot*, se procede a crear la ficha de registro del individuo, donde se registran datos como el peso, la estatura, el nombre completo, entre otros:

Figura 28: Ficha de registro de individuos, Ecofoot

- Posteriormente se realizó una grabación de análisis de tipo estático, debido a que éste, facilita el estudio de una postura fija del individuo a lo largo de toda la toma.
- Una vez finalizada la grabación de la toma por una ventana de tiempo predefinida, se obtienen mapas de presión en kilopascales (kPa) que corresponden al valor medio de todos los *n frames* capturados:

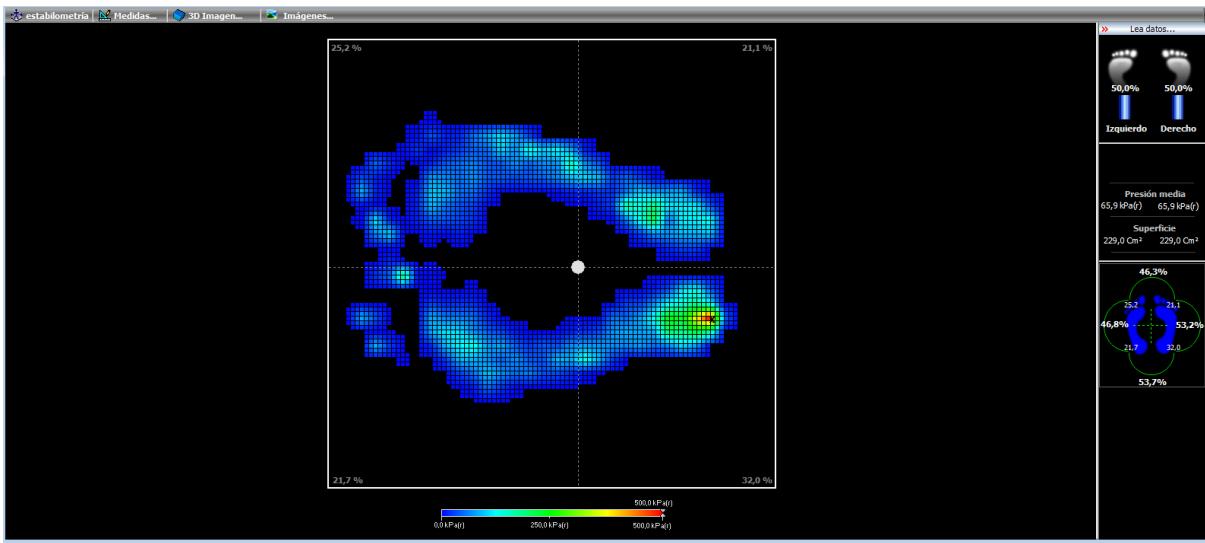


Figura 29: Registro de presión plantar, Ecofoot

Adicionalmente se pueden observar otras variables, como el porcentaje de distribución de presión por cada pie; y a su vez por cada zona del mismo.

- Finalmente, en la pestaña de estabilometría se observan cada una de las gráficas de oscilación del centro de presión a lo largo del tiempo. Éstas están divididas en oscilación lateral y anteroposterior, las cuales son producto de pequeñas compensaciones biológicas del equilibrio [27]:

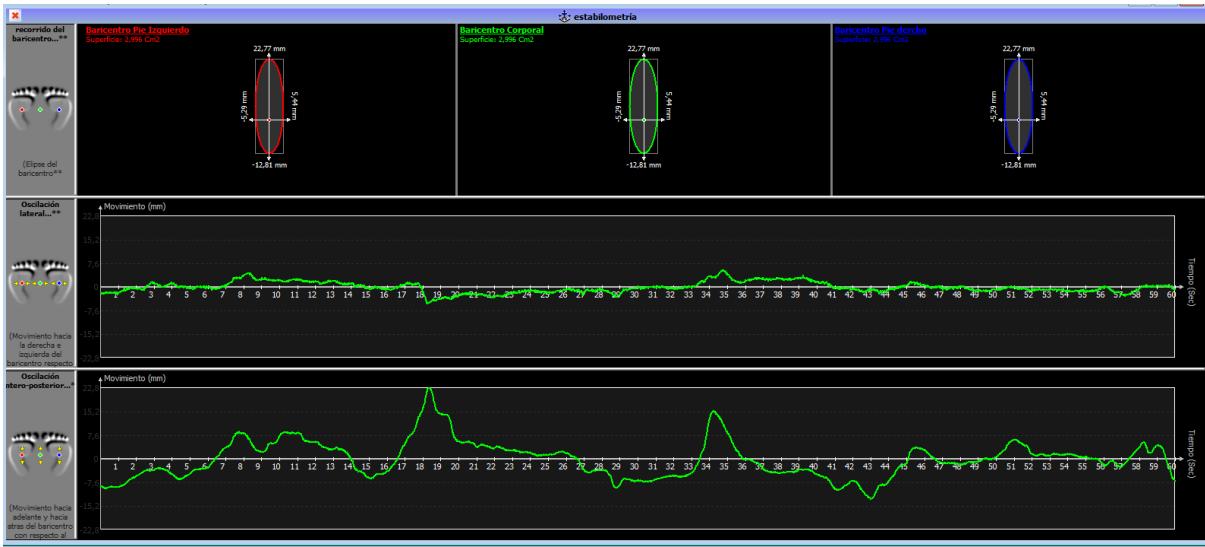


Figura 30: Gráficas de estabilometría - centros de presión, oscilación lateral y anteroposterior, Ecofoot

6.5. Procesamiento de datos

En esta sección se explicarán las técnicas empleadas para adecuar los conjuntos de datos de electroencefalografía y de estabilometría. Cuestiones como los nombres de los *dataframes*, las extensiones de archivo y detalles como los separadores de punto decimal y separadores de columnas, conciernen a esta fase.

6.5.1. Digitalización gráficas de estabilometría

La dificultad inicial que presentó la extracción de la base de datos de estabilometría residió en que las gráficas de oscilación lateral y anteroposterior no podían ser exportadas a manera de archivos de texto. Por lo tanto fue esencial realizar capturas de pantalla de todas las tomas, como se observa en la **figura 30**. Esto con el objetivo de digitalizar dichas series de tiempo en datos por medio de procesamiento de imagen. En ese orden de ideas, se hizo uso de la herramienta de *open-source Web-PlotDigitizer*. Este aplicativo semiautomático, favorece el uso de ingeniería inversa a las imágenes de las visualizaciones de datos para extraer los datos numéricos subyacentes [41]. Su adecuado funcionamiento, depende fundamentalmente de una correcta ubicación de los ejes de referencia para cada gráfica, para de esta manera, facilitar la búsqueda de píxeles en áreas específicas. A partir de la selección de un algoritmo de interpolación por pasos, se establecieron valores máximos y mínimos en cada eje y un ΔX de paso ($\Delta X = \frac{X_{max.}}{n.muestras}$), fueron obtenidas las series de tiempo para el movimiento del centro de presión.

El formato para los nombres de los archivos exportados fue el siguiente:

oscilacionXvoluntarioN.csv

Donde “***oscilacion***” corresponde al tipo de gráfica de oscilación según fuera el caso (anteroposterior/lateral), “***X***” corresponde al carácter A o C dependiendo de si fue una toma con ojos abiertos o cerrados, “***voluntario***” hace referencia al identificador dentro de la base de datos para cada voluntario y finalmente “***N***” corresponde al número de toma (1 a 5).

6.5.2. Conversión de archivos

Con motivo de que tanto los archivos de electroencefalografía, como los de estabilometría tenían como extensión de archivo **.csv**, se consideró como necesario realizar una conversión (por medio de Matlab) a **.xlsx** con el objetivo facilitar el manejo de los mismos y su visualización desde Excel. Sumado al hecho de que las gráficas de estabilometría tenían como separador decimal por defecto a la **coma** (,) cuestión que podría, por una parte afectar a la dimensionalidad individual de cada dato, y por otra parte, el ancho de las columnas ³. Los algoritmos implementados para cumplir con este cometido, en la totalidad de los dos grandes conjuntos de datos se muestra a continuación:

³Ya que la coma es generalmente utilizada como convención para la separación de columnas en un *dataframe*

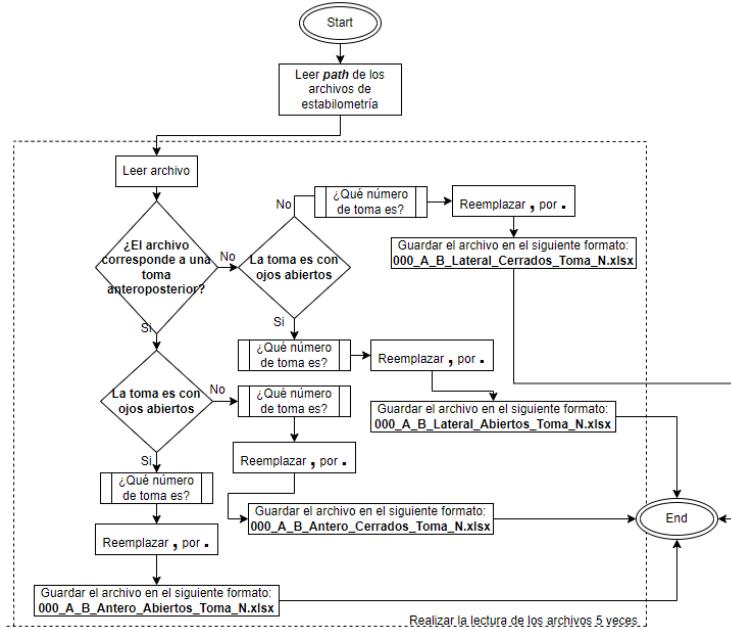


Figura 31: Diagrama de flujo algoritmo de conversión de archivos de estabilometría

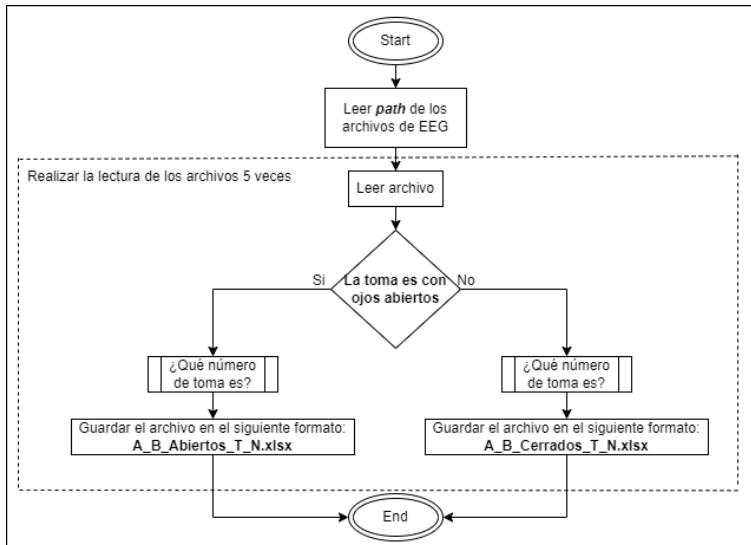


Figura 32: Diagrama de flujo algoritmo de conversión de archivos de electroencefalografía

6.5.3. Filtrado de canales EEG

Al momento de querer analizar datos *raw* (datos crudos o brutos) electroencefalografía en espectro de densidad de potencia, es determinante limpiar todos los canales de posibles interferencias, como señales de alta frecuencia (mayores a 100Hz), señales de tipo muscular (EMG), señales de red eléctrica o de artefactos tecnológicos, etc. Por lo tanto se hizo uso de un filtro, que además de eliminar interferencias externas a los canales de EEG, también atenuó las bandas de frecuencia⁴ que no tenían

⁴Como se puede observar, en la generalidad de las gráficas de potencia espectral de una señal EEG, se observa una importante subida en las frecuencias más bajas (aproximadamente entre 0 a 3Hz), esto puede entorpecer el análisis en cuanto a este proyecto se refiere

especial importancia en el análisis. [32]. En la siguiente figura se muestra la potencia espectral de 4 canales sin filtrar:

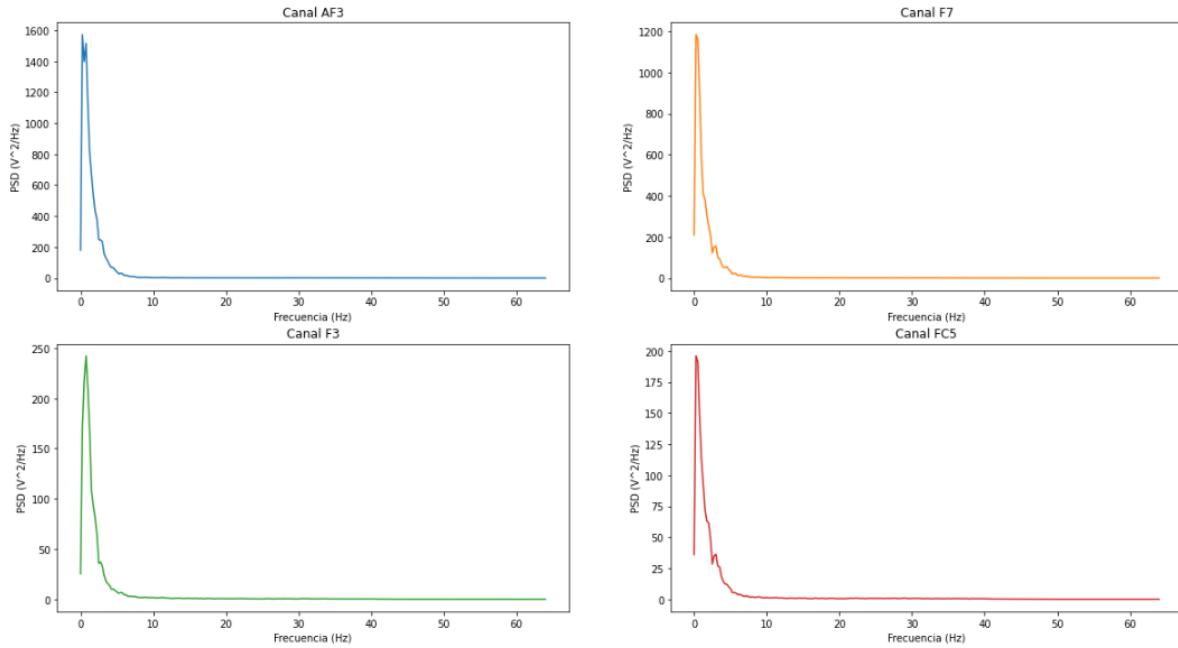


Figura 33: Respuesta característica en potencia espectral, de un canal de electroencefalografía

En este caso particular se seleccionó un filtro digital de tipo Butterworth pasabanda de cuarto orden, con corte en la banda de 6 a 30Hz⁵, a una frecuencia de muestreo de 128Hz⁶. La respuesta simulada tanto en magnitud como en fase se muestra a continuación:

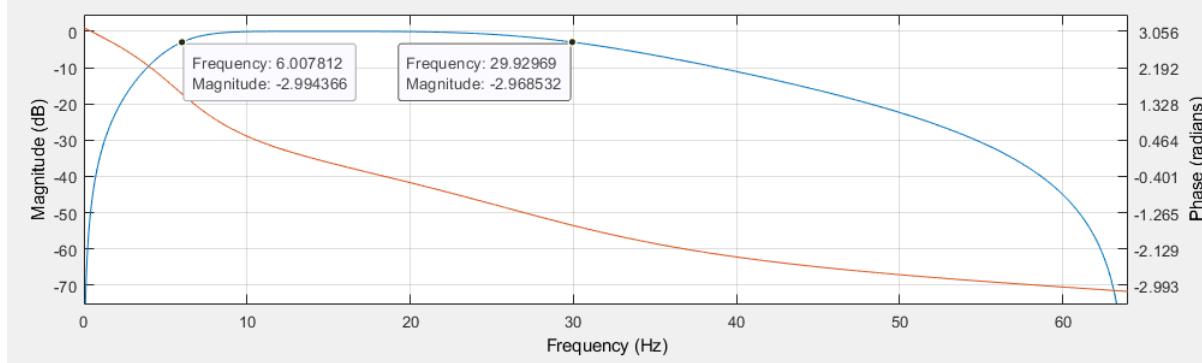


Figura 34: Respuesta en frecuencia y fase del filtro empleado. Obtenida de Matlab

6.6. Extracción de características

En consecuencia con una implementación de los métodos de aprendizaje de máquina, se hace necesaria la generación de una matriz que contenga características generales de los individuos, a partir de un procesamiento previo de las series de tiempo obtenidas anteriormente. A continuación se

⁵Las frecuencias de corte superior e inferior fueron seleccionadas debido a que las bandas de interés designadas de acuerdo al estado del arte [4], fueron alpha y beta

⁶La frecuencia de muestreo del filtro tiene una correspondencia directa con el muestreo predeterminado de EMOTIV utilizado en la toma de datos de electroencefalografía [38]

explicará el proceso por el cual pasaron cada uno de los conjuntos de datos de ambos sistemas para desembocar finalmente en los vectores de características que ingresaron en conjunto de datos a cada algoritmo de *machine learning*.

6.6.1. Análisis en PSD

El método seleccionado para el análisis espectral fue el método de Welch [34]. Éste calcula una estimación de la densidad espectral de potencia dividiendo la señal de electroencefalografía en segmentos superpuestos de la misma [35], obteniendo como resultante un periodograma modificado para cada segmento⁷. El criterio principal de selección de este tipo de estimación espectral, fue la capacidad de realizar periodogramas sin necesidad de tener señales estacionarias (invariantes en el tiempo) durante períodos considerables de tiempo. Por ejemplo, al estudiar 1 minuto en datos de una señal cualquiera de EEG, es prácticamente imposible descomponer la misma en una suma de funciones senoidales. Así pues, se tomó como punto de partida la selección de una duración (en segundos) adecuada para la ventana deslizante que abarcara por lo menos el doble de la frecuencia más baja de interés ($res = 2 \cdot \frac{1}{f}$). En el caso particular, se eligió una duración de 4 segundos para no afectar de manera tan drástica la resolución en frecuencia. No obstante, se usó la misma frecuencia de muestreo empleada en el filtro pasabanda (128Hz), de manera que $ventana = res \cdot Fs$. Por último se obtienen los vectores de componentes en frecuencia ($freqs(x)$) y de componentes en potencia ($psd(y)$) en unidades de $\frac{V^2}{Hz}$.

6.6.2. Normalización de canales

Normalmente el proceso de normalización en una base de datos equivale a una serie de procedimientos empleados con el fin de reducir redundancia entre los datos⁸, facilitar su manejo, y establecer un marco de referencia general para los mismos. Para los conjuntos de datos de EEG en cuestión fue necesario establecer un mismo orden de magnitud, esto, debido a ciertas diferencias entre los valores en magnitud de potencia espectral, tanto mínimos como máximos de todos los electrodos, al comparar algunas tomas frente a las demás. Condición posiblemente relacionada con la calidad de conectividad de los electrodos y el nivel de humedad de los mismos [42]. Para suplir esta disparidad entre tomas de datos diferentes, la normalización consistió de obtener el promedio total de las componentes en PSD de las 14 señales en cada adquisición, para luego dividir este cálculo entre cada uno de los canales individualmente.

6.6.3. Valores máximo y mínimo absolutos

Esta característica fue obtenida a partir de la inspección de las dos gráficas de estabilometría referentes a cada adquisición (lateral y anteroposterior). Como primera medida se obtienen los valores absolutos de valores pico máximos y mínimos de cada gráfica⁹. A causa de lo anteriormente mencionado, se aplicó el siguiente algoritmo responsable de la obtención de un máximo absoluto estabilométrico por toma:

⁷La operación de este método es comparable con promediar transformadas de Fourier consecutivas, de pequeñas ventanas de la señal EEG superpuestas

⁸Se considera que hay redundancia siempre que existan numerosos datos repetidos **que NO aporten información significativa** al análisis del *dataframe* en cuestión

⁹Esto se lleva a cabo, con el motivo de establecer una comparativa entre **distancias de desplazamiento** del centro de presión absolutas, y no **distancias recorridas** por el centro de presión con respecto a un plano de referencia.

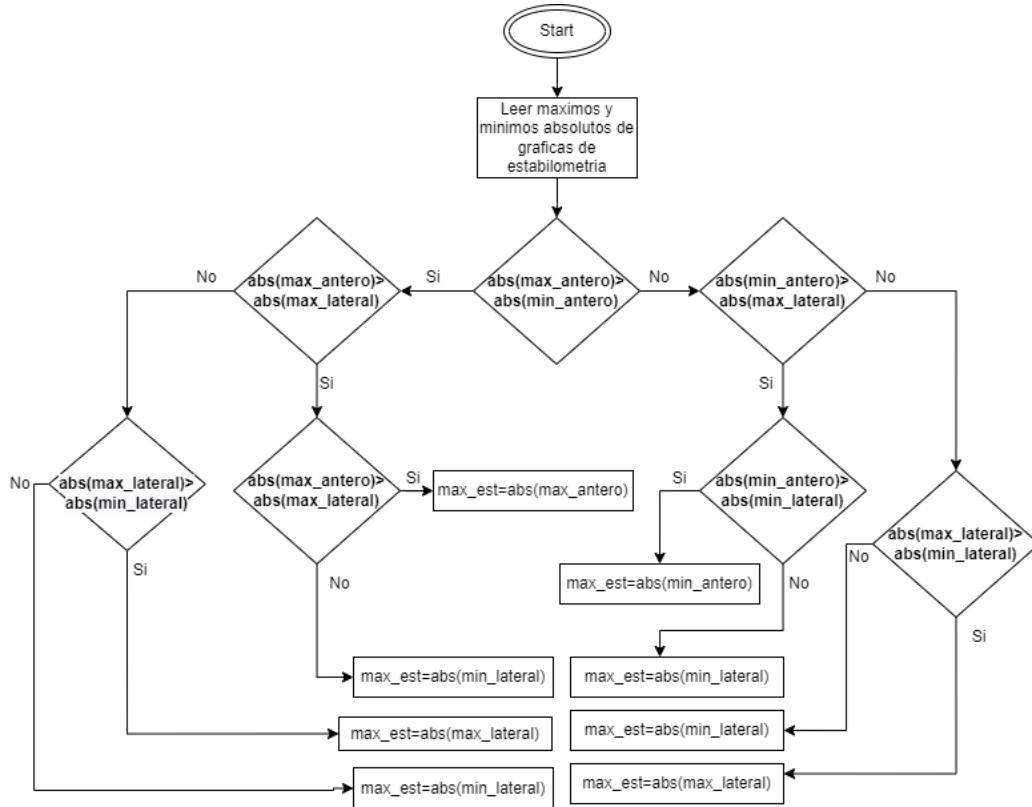


Figura 35: Condicional de máximo absoluto estabilométrico.

6.6.4. Desviación estándar

Es definida como una métrica de variabilidad de un conjunto de datos. Definida como la raíz cuadrada de la varianza, establece el nivel de cercanía de la mayor parte de datos con su media. De manera que una alta desviación estándar es el resultado de tener datos extendidos por un rango de valores más alto; en comparación a una baja desviación estándar, claro indicio de que la generalidad de los datos tiende a agruparse cerca de la media. Fueron tomadas como características, la desviación estándar de: las componentes de PSD máximas de todos los canales de EEG, oscilación lateral y oscilación anteroposterior.

$$s = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (xi - \mu)^2}$$

6.6.5. Matriz de salida

Una vez extraídas estas características (por cada voluntario), son asignadas a un vector de 21 columnas o posiciones, como se ilustra en la siguiente tabla:

AF3	F7	...	AF4	med_eeg	std_eeg	max_est	std_L	std_A	med_L	med_A
2.17	1.88	...	0.80	3.46607	1.2015	14.664	3.778	4.962	-0.190	0.126

Cuadro 2: Vector de características extraido por cada toma de datos

Donde las primeras 14 posiciones corresponden al valor máximo en componentes de PSD normalizado para cada electrodo, **med_eeg** corresponde a la media de todas las componentes de PSD, **std_eeg** corresponde a la desviación estándar de los canales en PSD, **max_est** corresponde al máximo absoluto de estabilometría, **std_L** hace referencia a la desviación estándar de la señal de oscilación lateral del COP, **std_A** corresponde a la desviación estándar de la señal de oscilación anteroposterior del COP, **med_L** corresponde a la media de la oscilación lateral y finalmente **med_A** corresponde a la media de oscilación anteroposterior. Teniendo en cuenta que este vector corresponde a cada toma individual, se obtuvieron los 50 vectores referentes a la totalidad de las tomas para posteriormente ser concatenados en una matriz de 21x50, utilizada en la implementación de los métodos de aprendizaje de máquina.

6.7. Métodos de aprendizaje de máquina

Para implementar los métodos de aprendizaje de maquina, fue necesario organizar los vectores de características dentro de un único *dataframe*. Durante el proceso de selección y descarte de los métodos más adecuados para la estimación de la estabilidad postural, el problema se bifurcó en regresión y clasificación. De manera que para la primera técnica de aprendizaje supervisado se esperaría hallar una correlación entre variables del sistema de estabilometría respecto a las de EEG. Como contrapartida, para el algoritmo de clasificación binaria, se esperaría estimar la pertenencia de un sujeto a la etiqueta **estable o inestable**.

Los criterios de selección de los métodos de regresión mas adecuados a implementar, fueron obtenidos a partir de las métricas resultantes del entrenamiento en la herramienta **Regression Learner**. Esta *app* provista por Matlab, entrena diferentes modelos con la finalidad de predecir datos, tomando un conjunto conocido de observaciones (predictores) y relacionándolo con un conjunto de respuestas conocidas [43]. Para el caso del método de clasificación, se hizo uso de la herramienta **Classification Learner**, provista también por Matlab. En este ultimo caso, se relaciona el conjunto de datos con una etiqueta de clase.

6.7.1. Gaussian Progress Regression (Optimizable GPR)

El primer modelo de regresión seleccionado para el entrenamiento del conjunto. Es un método no paramétrico generalmente empleado en búsqueda aleatoria [44]. La métrica diferencial para seleccionarlo sobre otros, fue el valor de R^2 obtenido durante el entrenamiento. También conocido como coeficiente de determinación, corresponde a la métrica de proporción de varianza de la variable dependiente. Es decir, que tan bien se ajustan los datos (en este caso electroencefalografía), al modelo de regresión. Para este modelo de regresión, se observa un 37 % de variabilidad observada en la variable **STD_LATERAL** correspondiente a la desviación estándar de la gráfica de oscilación lateral, y seleccionada como objetivo.

Tipo de modelo	Regresión
Resultados de entrenamiento	
R^2	0.37
MAE	1.26
RMSE	2.02

Cuadro 3: Resultados de entrenamiento - Optimizable GPR

A continuación se observa el gráfico predicho de la regresión:

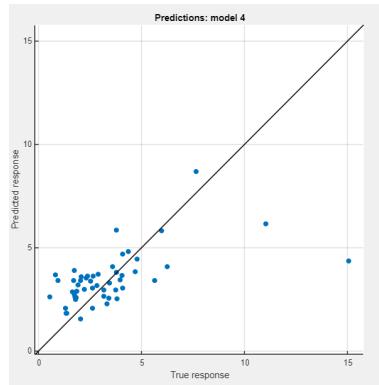


Figura 36: Gráfico de predicciones - Optimizable GPR

6.7.2. Gaussian Progress Regression (Squared Exponential GPR)

Al igual que en el caso de la anterior regresión, el método de interpolación proviene del *kriging* o regresión en proceso gaussiano. Para el método en cuestión, se obtuvo un coeficiente de determinación del 38 %, aunque a primera vista parece un rendimiento bajo, puede considerarse que mas de la tercera parte de los datos de la oscilación lateral, se basa en el conjunto de electroencefalografía. No obstante, la naturaleza de las variables empleadas en el modelo (sistemas biológicos diferentes) condicionan fuertemente este resultado en cuanto a rendimiento se refiere. En la siguiente tabla se observan otras métricas de rendimiento correspondientes al modelo como el error cuadrático medio y el error absoluto medio:

Tipo de modelo	Regresión
Resultados de entrenamiento	
R^2	0.38
MAE	1.27
RMSE	2.01

Cuadro 4: Resultados de entrenamiento - Squared Exponential GPR

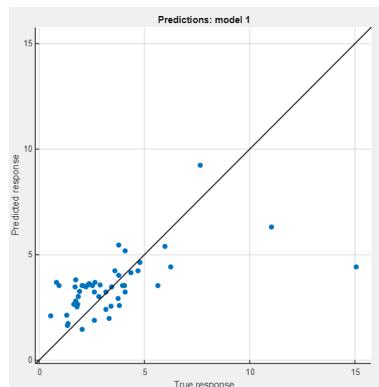


Figura 37: Gráfico de predicciones - Squared Exponential GPR

6.7.3. Kernel Naive Bayes

El clasificador Naive Bayes es uno de los clasificadores probabilísticos más simples basado en el teorema de Bayes. Este asume que la presencia de una característica particular de una clase no está relacionada con la presencia de ninguna otra característica. De manera que todas las características contribuyen de manera independiente a la probabilidad de pertenencia a la clase estable o inestable, para el caso en cuestión.

Por otra parte, este clasificador, requiere una pequeña cantidad de datos de entrenamiento para la clasificación. El operador Naive Bayes Kernel, puede ser aplicado a atributos numéricos. En ese orden de ideas, la etiqueta estuvo condicionada por el conjunto de estabilometría. Este fue el resultado del entrenamiento del conjunto de EEG usado para el clasificador binario:

Tipo de modelo	Clasificación
Resultados de entrenamiento	
AUC	0.68
Costo (Validación)	16
Tipo de Kernel	Gaussiano

Cuadro 5: Gráfico de predicciones - Kernel Naive Bayes

A partir de lo anterior, se determina una razón en la clasificación del conjunto de entrenamiento cercana al 70 %. A continuación se muestran los resultados del entrenamiento en forma gráfico de AUC y matriz de confusión:

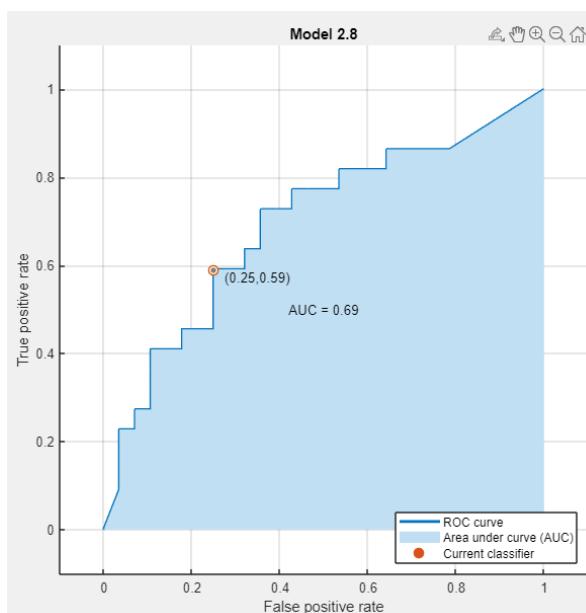


Figura 38: Curva ROC - Kernel Naive Bayes

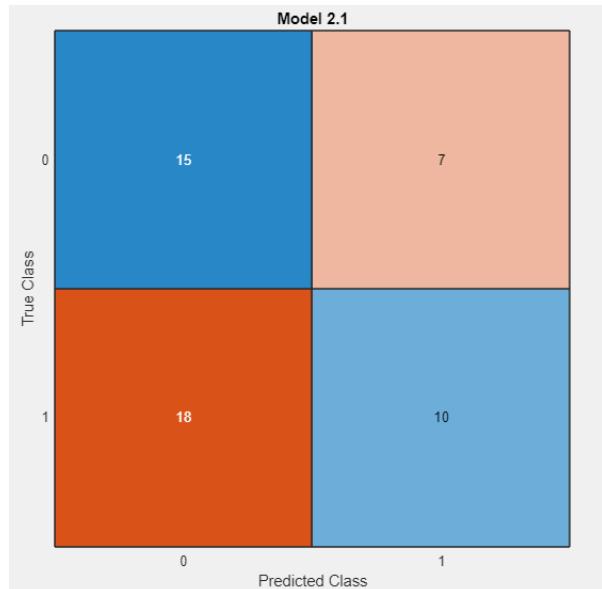


Figura 39: Matriz de confusión - Kernel Naive Bayes

Finalmente, teniendo en cuenta que se trata de una clasificación binaria, se usó como métrica de evaluación la medida más simple del coeficiente de correlación de Matthews o por sus siglas en inglés: **MCC**. Para ello se hizo uso de la matriz de confusión mostrada anteriormente, que relacionaba los verdaderos positivos (VP), verdaderos negativos (VN), falsos positivos (FP), y los falsos negativos (FN) [45], tal y como se observa en la siguiente tabla:

		Valores reales	
		Estable	Inestable
Valores predichos	Estable	VP	FP
	Inestable	FN	VN

Cuadro 6: MCC - Estabilidad/Inestabilidad

La expresión general para el cálculo del MCC en una clasificación binaria surge a partir de la siguiente fórmula:

$$\text{MCC} = \frac{(VP \cdot VN - FP \cdot FN)}{\sqrt{(VP + FP) \cdot (VP + FN) \cdot (VN + FP) \cdot (VN + FN)}}$$

De manera que se obtiene como resultado para el MCC : 0,041

7. Resultados

7.1. Justificación de la visualización de los resultados

Los resultados, referentes a los **datos procesados de EEG** correspondientes a la toma general, separados en los dos grandes grupos de **ojos abiertos** y **ojos cerrados**, fueron analizados desde el punto de vista estadístico, mediante el aprovechamiento de diagramas caja y bigotes o *boxplot*. Este es un método útil en sentido de representar los cuartiles y la mediana de una serie de datos [46]. Además incluye la visualización de los siguientes elementos:

- Rango
- Datos atípicos
- Mediana
- Máximo y mínimo

7.2. Resultados de distribucion de PSD: Ojos Abiertos vs Ojos Cerrados

A continuación se muestran los *boxplots* correspondientes a la totalidad de la toma de datos separadas en los dos grandes grupos ya conocidos. Por lo que fueron agrupadas las 10 tomas de cada de cada uno de los 5 voluntarios (5 con ojos abiertos y 5 con ojos cerrados), con la finalidad de observar la dispersión de potencia por canales de EEG en la generalidad de la adquisición para cada canal de electroencefalografía.

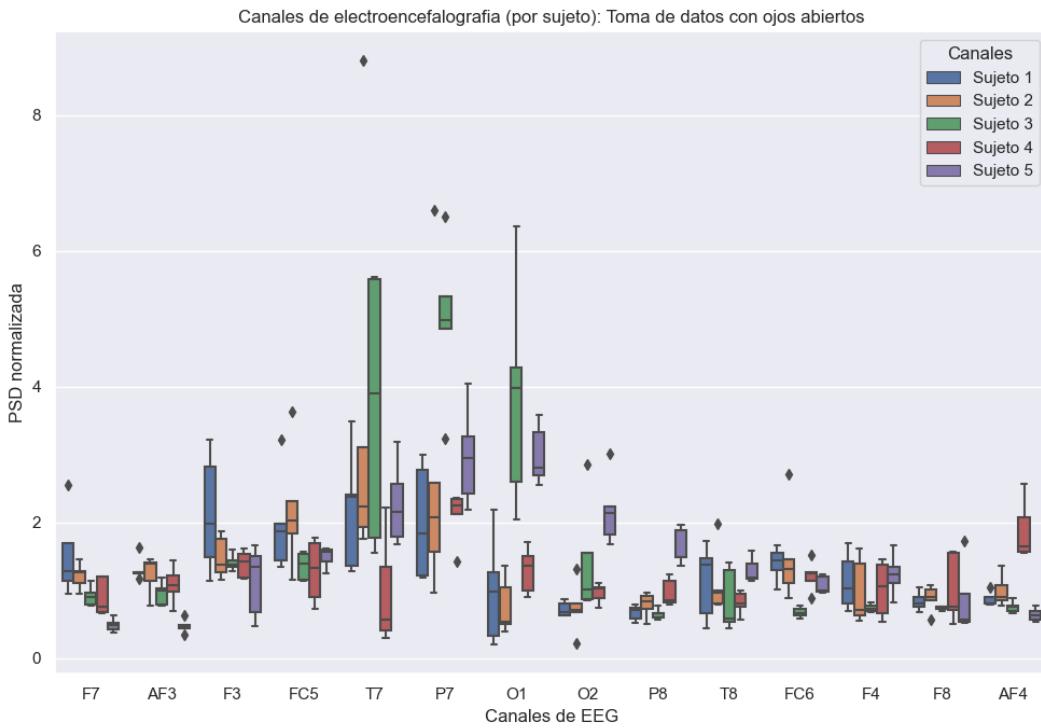


Figura 40: Distribucion de las bandas α y β en canales de EEG: Toma de datos completa (5 sujetos)
- Ojos abiertos.

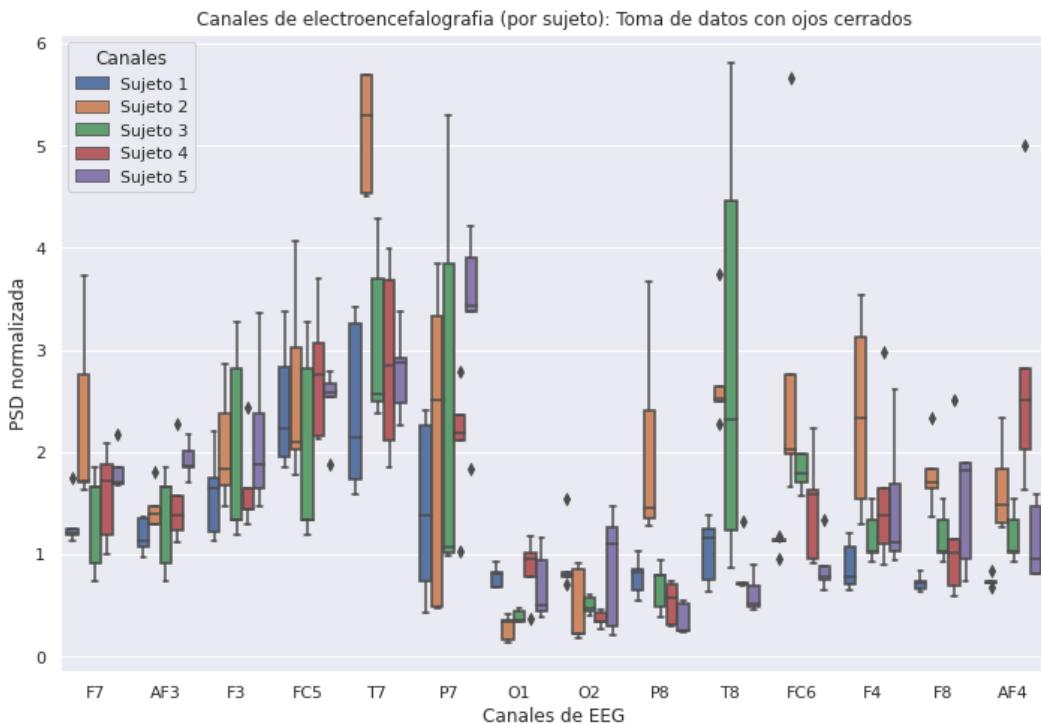


Figura 41: Distribucion de las bandas α y β en canales de EEG: Toma de datos completa (5 sujetos)
- Ojos cerrados.

En contraste con lo encontrado y estudiado el estado del arte, los resultados de la muestra general se ajustan a lo esperado, ya que la separación por canales permite contemplar la dispersión de densidad de potencia espectral en las bandas prioritarias dentro del análisis de estabilidad. Justamente el comportamiento de los datos obtenidos con los dos electrodos ubicados en la zona occipital (O1 y O2), en la parte frontal (T3 y F4) y en la parietal (P7 y P8) denota un claro cambio en la dispersión evaluada. De acuerdo con Khorev [4] esta variación puede asociarse a un intento por preservar la estabilidad postural.

Ahora bien, al confrontar la generalidad de las diferentes dispersiones en las tomas con ojos abiertos contrapuestos a ojos cerrados, se observa una amplio aumento de dispersión en el grupo de ojos cerrados para la mayor parte de los electrodos. Como observación adicional, es viable comentar que la dinámica espectral puede presentarse de manera inversa a lo realizado en el experimento referenciado debido a la normalización de los canales. Teniendo valores pico en análisis espectral (antes de seleccionar y exportar características) más elevados los electrodos donde se observa una distribución en valores mas pequeños.

8. Análisis de resultados

Una vez validado y comparado el estado del arte con resultados grupales, se evalúa la distribución de potencia cortical **normalizada** en bandas alfa y beta para cada uno de los voluntarios en la toma de datos para sus dos variante. Cabe resaltar que nuevamente se reúnen las 5 adquisiciones para cada estado.

8.0.1. Primer voluntario

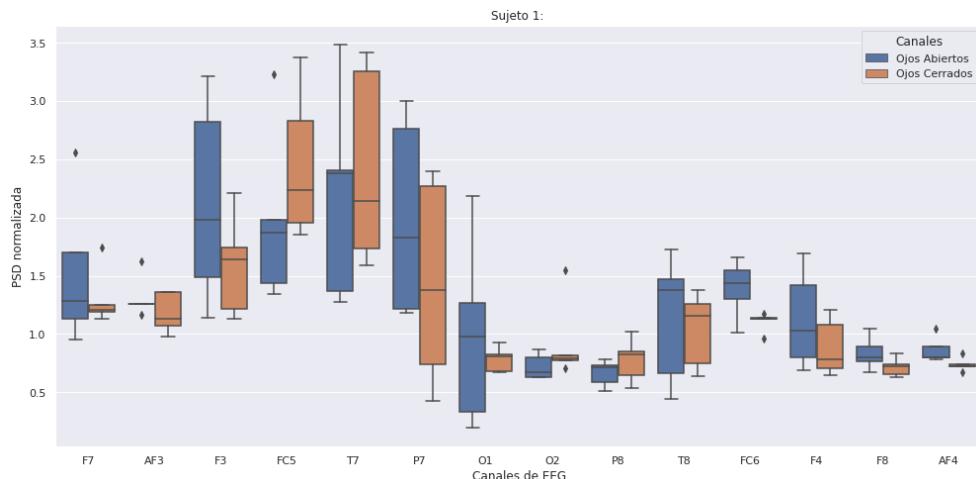


Figura 42: Toma de datos: Voluntario 1 - Ojos cerrados vs ojos abiertos.

Inicialmente, los electrodos que más destacan por una distribución relativamente simétrica (exceutando el temporal izquierdo con ojos abiertos) y por una amplia distribución, son el temporal izquierdo (T7) y el parietal izquierdo (P7) tanto en el caso de ojos abiertos como cerrados. Ello podría asociarse a cambios mínimos en valores de densidad potencia para el caso de este primer individuo, al momento de querer conservar la estabilidad. Contrario a lo obtenido en el caso de ambos electrodos situados en la zona occipital del cráneo (O1 y O2), ambos asociados a funcionalidades de visión, movimientos y profundidad. Allí se marca una clara característica diferencial entre la potencia con

ojos abiertos y cerrados, dado que definitivamente aumenta el esfuerzo por preservar la estabilidad en posición bípeda para la segunda situación.

8.0.2. Segundo voluntario

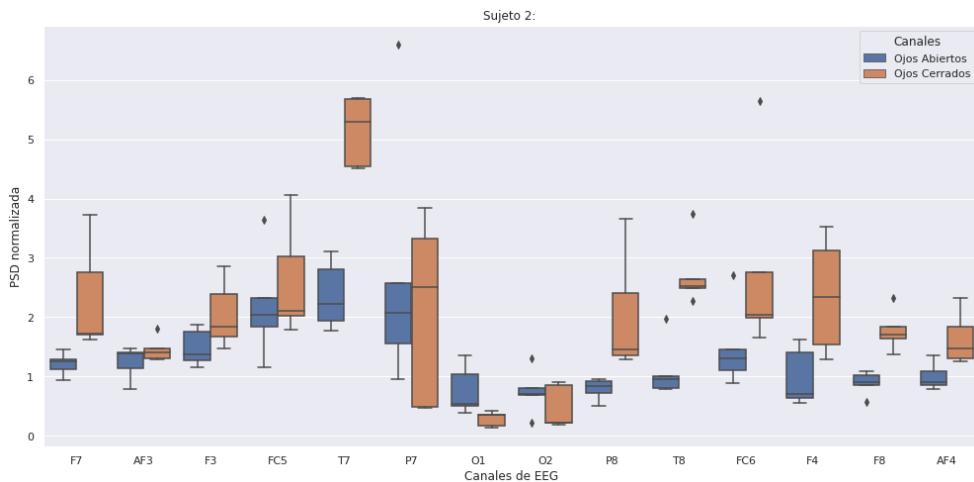


Figura 43: Toma de datos: Voluntario 2 - Ojos cerrados vs ojos abiertos.

Luego de observar los resultados obtenidos de las 10 tomas con el segundo voluntario, se contrasta un comportamiento completamente opuesto respecto al primero: un claro aumento de la distribución de densidad de potencia normalizada en las adquisiciones con ojos cerrados. Esto podría ser un indicativo de que el individuo conserva mejor el equilibrio al estar con ojos cerrados, y con poco esfuerzo aparente. Nuevamente los canales correspondientes a la zona occipital tienen ordenes de magnitud comunes y presentan un comportamiento similar a la generalidad de las tomas dentro del conjunto de datos.

8.0.3. Tercer voluntario

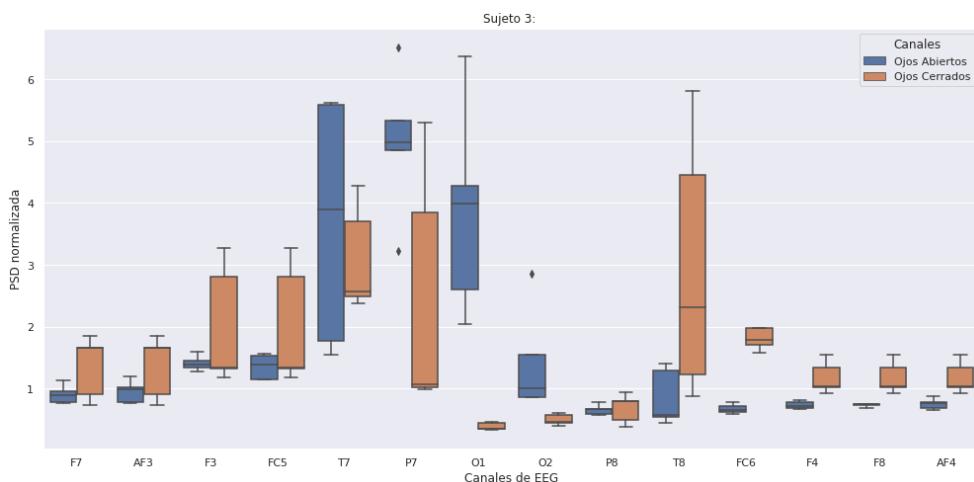


Figura 44: Toma de datos: Voluntario 3 - Ojos cerrados vs ojos abiertos.

Presentando las dispersiones más altas en comparación con los demás individuos, sobresalen los canales situados en: temporal izquierdo con ojos abiertos (con una distribución casi completamente simétrica), el parietal izquierdo con ojos cerrados y el temporal derecho. Una alta densidad de potencia normalizada en los canales temporales, podría asociarse a una baja dinámica en las zonas 41 y 42 de Brodmann, asociadas al funcionamiento del sistema vestibular.

8.0.4. Cuarto voluntario

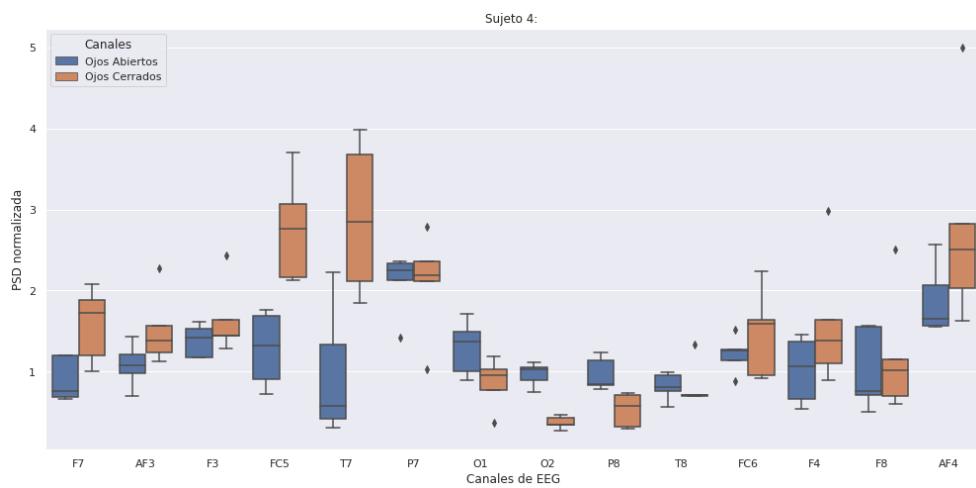


Figura 45: Toma de datos: Voluntario 4 - Ojos cerrados vs ojos abiertos.

Para el cuarto voluntario se visualiza una distribución completa de la adquisición, con tendencia al comportamiento más constante del conjunto de datos. De acuerdo a ello, podría afirmarse que es el más estable de los 5 voluntarios. Nuevamente, se contempla una dinámica habitual de una persona que realiza esfuerzos más por preservar la estabilidad con ojos cerrados, con descensos en la distribución de PSD normalizada para los canales occipitales y parietales, y un aumento en uno de los temporales de la toma con ojos abiertos.

8.0.5. Quinto voluntario

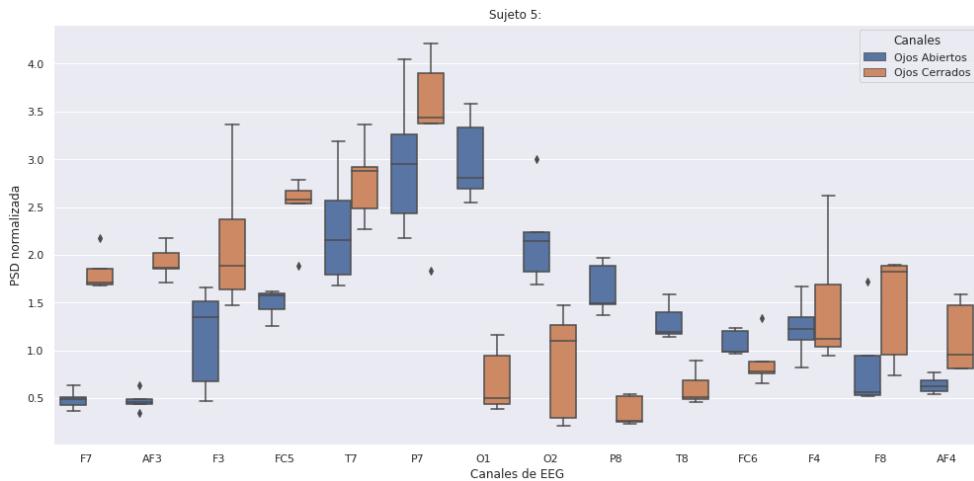


Figura 46: Toma de datos: Voluntario 5 - Ojos cerrados vs ojos abiertos.

En el caso del ultimo voluntario, se observa el menor orden de magnitud en la generalidad de la distribución de densidad de potencia correspondiente a la toma. En las tomas con ojos abiertos se sigue una tendencia a una disminución en los canales frontales y un aumento en los electrodos temporales, parietales y occipitales asociados al sistema vestibular, la percepción sensorial y la información sensitiva, y las funcionalidades de visión respectivamente. De acuerdo a esto, podría afirmarse que en conjunto, la distribución de la muestra con ojos abiertos representa todos los indicativos de un ser humano que se encuentra en situación de inestabilidad. Al revisar las distribuciones completas de las tomas con ojos cerrados, más específicamente en los canales occipitales, se visualiza un claro descenso respecto a la toma con abiertos. Si bien la toma completa, denota la dinámica de un individuo con baja estabilidad, este ultimo aspecto claramente representa un esfuerzo mayor por preservar el equilibrio al estar con ojos cerrados.

9. Conclusiones

La inestabilidad postural puede efectivamente asociarse con características específicas de la actividad cortical. De manera que pueden considerarse como indicativo biológico de inestabilidad o inestabilidad los cambios en la distribución de densidad de potencia espectral en las bandas alfa y beta. Por otra parte, la normalización de una toma de datos con seres humanos resulta en una técnica indispensable para la obtención de un conjunto de datos uniforme y analizado en un mismo orden de magnitud. Dado que entre grupos poblacionales sanos con condiciones físicas “similares” pueden haber marcadas diferencias a la luz de exploraciones como la electroencefalografía y la estabilometría. Justamente en el caso de la primera exploración, al evaluar la conservación de estabilidad postural desde los canales de EEG, se concluyó como pertinente tomar en consideración la totalidad de los canales y no únicamente los situados en la zona frontal parietal, asociada principalmente con la corteza sensoriomotora. Esto debido a que la dinámica en conjunto aportó información valiosa para el análisis en cuestión. Esta información, contemplada a manera de *boxplot* denotó una amplia dispersión en el análisis PSD en los canales de EEG prioritarios en la conservación de estabilidad, en la totalidad de las tomas con ojos cerrados fue una clara señal de un esfuerzo mayor realizado por los individuos, con el fin de preservar el equilibrio frente a las tomas con ojos abiertos.

Como contrapartida, el análisis en métricas de rendimiento obtenido posterior a la implementación de los dos algoritmos de aprendizaje de máquina para regresión, no indicó un indicio claro de la obtención de la **totalidad** de un conjunto de datos a partir del otro, sin embargo cerca de un 40 % de la variación de los datos de oscilación lateral podría llegar a predecirse a partir de EEG. Finalmente, para la clasificación binaria por medio de *machine learning*, se concluyó que la escogencia de valores que superen umbrales de estabilometría podría considerarse una métrica biológica viable de estabilidad o inestabilidad. Esto, teniendo en cuenta que para la selección de una etiqueta adecuada de estabilidad se hizo uso de máximos absolutos y su posterior condicionamiento obteniendo un AUC de 68 % por medio de Kernel Naive Bayes.

10. Trabajos futuros

- Para el futuro se sugeriría la utilización de un equipo de electroencefalografía, en la adquisición de datos corticales que sea *open-source* (con la intención de abaratrar costos del proyecto) y que cuente con más canales para mejorar el análisis con información adicional de otros electrodos.
- Se considera viable la implementación de un sistema para la estimación de la estabilidad postural en tiempo real, sin embargo se deben investigar técnicas existentes para conseguir una exportación de datos sincrónica y la utilización de redes neuronales para el post-procesamiento.
- Un objeto de investigación a considerar podría ser el desarrollo de una interfaz gráfica de usuario para facilitar la utilización del sistema a profesionales de la salud sin conocimientos necesariamente técnicos en el área de electrónica, *machine learning* y procesamiento de señales.
- Se sugiere la adquisición de una muestra más grande (con un número mayor de individuos y de tomas con ojos abiertos y cerrados), de forma que se obtengan muchos más vectores característicos que constituyan el dataframe en que se implementen los algoritmos para la estimación de relación entre estabilometría y EEG.

11. Anexos

- Protocolo de toma de datos con voluntarios.
- Diagramas de flujo.
- Dataframe con las características de las 50 tomas.
- Modelos entrenados e implementación de los 3 métodos.

Referencias

- [1] L. Wei, Q. Hong, H. Yue, and C. Xi, "The research in a plantar pressure measuring system connected with eeg," in *IEEE 10th INTERNATIONAL CONFERENCE ON SIGNAL PROCESSING PROCEEDINGS*, pp. 434–437, 2010.
- [2] K. Safi, S. Mohammed, Y. Amirat, and M. Khalil, "Postural stability analysis — a review of techniques and methods for human stability assessment," in *2017 Fourth International Conference on Advances in Biomedical Engineering (ICABME)*, pp. 1–4, 2017.
- [3] S. Kwon and Y. Oh, "Estimation of the center of mass of humanoid robot," in *2007 International Conference on Control, Automation and Systems*, pp. 2705–2709, 2007.
- [4] V. Khorev, V. Grubov, A. Badarin, and V. Maksimenko, "EEG features during maintaining a human body balance.," in *2020 International Conference Nonlinearity, Information and Robotics (NIR)*, pp. 1–4, 2020.
- [5] M. A. Yokus and J. S. Jur, "Fabric-based wearable dry electrodes for body surface biopotential recording," *IEEE Transactions on Biomedical Engineering*, vol. 63, no. 2, pp. 423–430, 2016.
- [6] H. Piroska and S. Janos, "Specific movement detection in eeg signal using time-frequency analysis," in *2008 First International Conference on Complexity and Intelligence of the Artificial and Natural Complex Systems. Medical Applications of the Complex Systems. Biomedical Computing*, pp. 209–215, 2008.
- [7] A. Díaz, I. y Molina, "Todo lo que debes saber sobre el potencial de acción," *mDurance estudio*, 2022.
- [8] Wikipedia, "Prefrontal cortex — Wikipedia, the free encyclopedia." <http://en.wikipedia.org/w/index.php?title=Prefrontal%20cortex&oldid=1120151507>, 2022. [Online; accessed 06-November-2022].
- [9] N. UFRO, "Oído interno." https://www.med.ufro.cl/neuroanatomia/archivos/fono_ocio_archivos/Page342.htm. Accessed: 2022-03-28.
- [10] AUDIFONO.NET, "Nuevo estudio muestra que la pérdida auditiva relacionada con la edad se debe principalmente al daño a las células ciliadas." <https://audifono.net/noticias/nuevo-estudio-muestra-que-la-perdida-auditiva-dano-a-las-celulas-ciliadas/>. Accessed: 2022-03-28.
- [11] I. U. de Oftalmología Aplicado, "Las partes del ojo." <https://www.ioba.es/2021/09/01/las-partes-del-ojo/>. Accessed: 2022-03-28.
- [12] S. I. Fox, *Fisiología sensorial*. New York, NY: McGraw-Hill Education, 2017.
- [13] E. Heydari and M. Shahbakhti, "Adaptive wavelet technique for eeg de-noising," in *2015 8th Biomedical Engineering International Conference (BMEiCON)*, pp. 1–4, 2015.
- [14] OMS, "Caídas." <https://www.who.int/es/news-room/fact-sheets/detail/falls>. Accessed: 2022-02-28.
- [15] A. J. CAMPBELL, J. REINKEN, B. C. ALLAN, and G. S. MARTINEZ, "Falls in old age: A study of frequency and related clinical factors," *Age and Ageing*, vol. 10, pp. 264–270, 11 1981.

- [16] H. E. Richardson JK, Ching C, “The relationship between electromyographically documented peripheral neuropathy and falls,” *J Am Geriatr Soc*, 1992.
- [17] G. Wu, “Real-time feedback of body center of gravity for postural training of elderly patients with peripheral neuropathy,” *IEEE Transactions on Rehabilitation Engineering*, vol. 5, no. 4, pp. 399–402, 1997.
- [18] H. S. . K. Booth, Hoefnagels, “PAPPI: Personalized analysis of plantar pressure images using statistical modelling and parametric mapping.,” 2020.
- [19] R. A. Bhandari and D. S. Morrell, *Enfermedades cutáneas: extremidades*. New York, NY: McGraw-Hill Education, 2018.
- [20] “IEEE recommended practice on software reliability, IEEE Std 1633-2016 (Revision of IEEE Std 1633-2008),” standard, IEEE, 2017.
- [21] “IEEE standard for system, software, and hardware verification and validation”, ieee std 1012-2016 (revision of ieee std 1012-2012/ incorporates ieee std 1012-2016/cor1-2017),” standard, IEEE, 2017.
- [22] “Normas de ética médica, ley 23 de 1981,” standard, Congreso de la República de Colombia, 2022.
- [23] “Norma EN 60601-1,” standard, BSI, 2022.
- [24] “ISO 27001,” standard, International Organization for Standardization, 2022.
- [25] “Ley de protección de datos personales, ley 1581 de 2012,” standard, Congreso de la República de Colombia, 2022.
- [26] A. H. Ropper, M. A. Samuels, J. P. Klein, and S. Prasad, *Trastornos de la bipedestación y la marcha*. New York, NY: McGraw-Hill Education, 2020.
- [27] D. Winter, “Human balance and posture control during standing and walking,” *Gait Posture*, vol. 3, no. 4, pp. 193–214, 1995.
- [28] D. Krebs, “Is base of support greater in unsteady gait?,” (2002).
- [29] M. Ángel López Gordo, “Interfaz BCI de altas prestaciones basada en la detección y procesamiento de la actividad cerebral (BCI-depracap),” *Universidad de Granada*, 2009.
- [30] J. H. Martin, *Organización estructural y funcional del sistema nervioso central*. New York, NY: McGraw-Hill Education, 2015.
- [31] B. Goldman and P. Johns, *Vertigo*. New York, NY: McGraw-Hill Education, 2020.
- [32] R. Jenke, A. Peer, and M. Buss, “Feature extraction and selection for emotion recognition from eeg,” *IEEE Transactions on Affective Computing*, vol. 5, no. 3, pp. 327–339, 2014.
- [33] G. Geetha and Dr.S.N.Geethalakshmi, “Scrutinizing different techniques for artifact removal from eeg signals,” *International Journal of Engineering Science and Technology*, vol. 3, 02 2011.
- [34] C. W. Fadzal, W. Mansor, Z. Khuan, S. Mohamad, and Amirin, “Welch power spectral density of eeg signal generated from dyslexic children,” in *2014 IEEE REGION 10 SYMPOSIUM*, pp. 560–562, 2014.

- [35] Physionet, “Welch: Promediado de periodogramas modificados.” <http://physionet.cps.unizar.es/~eduardo/docencia/tds/librohtml/welch1.htm>. Accessed: 2022-11-06.
- [36] “CDIO™ initiative: Conceive,design,implement, operate,” standard, Chalmers University of Technology, 2022.
- [37] L. H. O. J. Klem, G. H., *The ten-twenty electrode system of the International Federation*. Electroencephalography and clinical neurophysiology, 1999.
- [38] EMOTIV, “Epoc+ user manual.” <https://emotiv.gitbook.io/epoc-user-manual/troubleshooting/saline-solution>. Accessed: 2022-11-09.
- [39] M. A. Sovierzoski, F. I. M. Argoud, and F. M. de Azevedo, “Identifying eye blinks in eeg signal analysis,” in *2008 International Conference on Information Technology and Applications in Biomedicine*, pp. 406–409, 2008.
- [40] M. L. Zequera, O. L. Perdomo, C. Wilches, and P. R. Vizcaya, “Pilot study : Biomechanical assessment of the plantar pressure distribution in healthy subjects using the pressure platform ecowalk,” 2014.
- [41] A. Rohatgi, “WebPlotDigitizer,” 8 2021.
- [42] M. Jones, “Comparing dc offset and impedance readings in the assessment of electrode connection quality,” *NeuroRegulation*, vol. 2, 04 2015.
- [43] MATLAB, *Train Regression Models in Regression Learner App*. Natick, Massachusetts: The MathWorks Inc., 2018.
- [44] S. Manzhos and M. Ihara, “On the optimization of hyperparameters in gaussian process regression with the help of low-order high-dimensional model representation,” 2021.
- [45] D. Chicco, V. Starovoitov, and G. Jurman, “The benefits of the matthews correlation coefficient (mcc) over the diagnostic odds ratio (dor) in binary classification assessment,” *IEEE Access*, vol. 9, pp. 47112–47124, 2021.
- [46] Wikipedia, “Diagrama de caja — Wikipedia, the free encyclopedia.” <http://es.wikipedia.org/w/index.php?title=Diagrama%20de%20caja&oldid=143928161>, 2022. [Online; accessed 14-November-2022].